

DATAPATH · AI SOLUTIONS ARCHITECT · PROYECTO FINAL · COHORTE 2026-08

Mesa de preautorización de procedimientos programados

Vitalia Salud EPS · Perú — rediseño del proceso y arquitectura de IA

Fase 1 · diseño, business case y production readiness

AUTOR
Jonatan Sánchez

FECHA
2026-09-05

PRESENTACIÓN
11 láminas + 7 planos a página completa

ANEXOS
A–J · 11 documentos · 14 planos

ALCANCE
Nivel de diseño · el MVP es fase 2

EL SECTOR · ASEGURAMIENTO PRIVADO EN SALUD, PERÚ

Una aseguradora cobra una **cuota mensual fija** por persona cubierta y paga las atenciones que necesite, dentro de los límites de su plan.

IAFAS financian (EPS, seguros, EsSalud, SIS) · **IPRESS** atienden (clínicas y hospitales) · **SUSALUD** fiscaliza plazos, cobertura y sustento, y sanciona. Una **EPS** es la figura regulada por la que una empresa redirige parte del aporte obligatorio de sus trabajadores hacia una cobertura privada.

EL CLIENTE · VITALIA SALUD EPS

Quién paga	Empresas — contratos corporativos
Quién usa	El afiliado : el trabajador y su familia
Tamaño	165,000 afiliados vigentes
Portafolio	Esencial 26% · Integral 62% · Premium 12%
Regulador	SUSALUD · Ley 29733 de datos personales

EL PROCESO · PREAUTORIZACIÓN

Cuando un médico indica un procedimiento caro y programable, **la clínica no lo ejecuta hasta que Vitalia diga que sí**. La mesa decide si se autoriza y con qué copago.

Sí requieren permiso: cirugías electivas, hospitalizaciones programadas, imágenes de alto costo, oncología, prótesis, terapias largas y atención en el extranjero.

No lo requieren: consultas ambulatorias, análisis de rutina ni emergencias.

En seguros de salud	Qué es	Equivalente en otro sector
Prima	Pago mensual por estar cubierto	La cuota del plan o la suscripción
Prestador	Clínica u hospital que atiende	El comercio afiliado donde se consume
Copago	Lo que paga el afiliado en cada atención	La franquicia o el cargo por transacción
Carencia	Espera tras contratar antes de usar un beneficio	Permanencia mínima antes de habilitar el beneficio
Exclusión	Lo que el contrato explícitamente no cubre	La letra pequeña del contrato
Preactorización	Permiso previo antes de un procedimiento caro	La autorización de una transacción antes del consumo

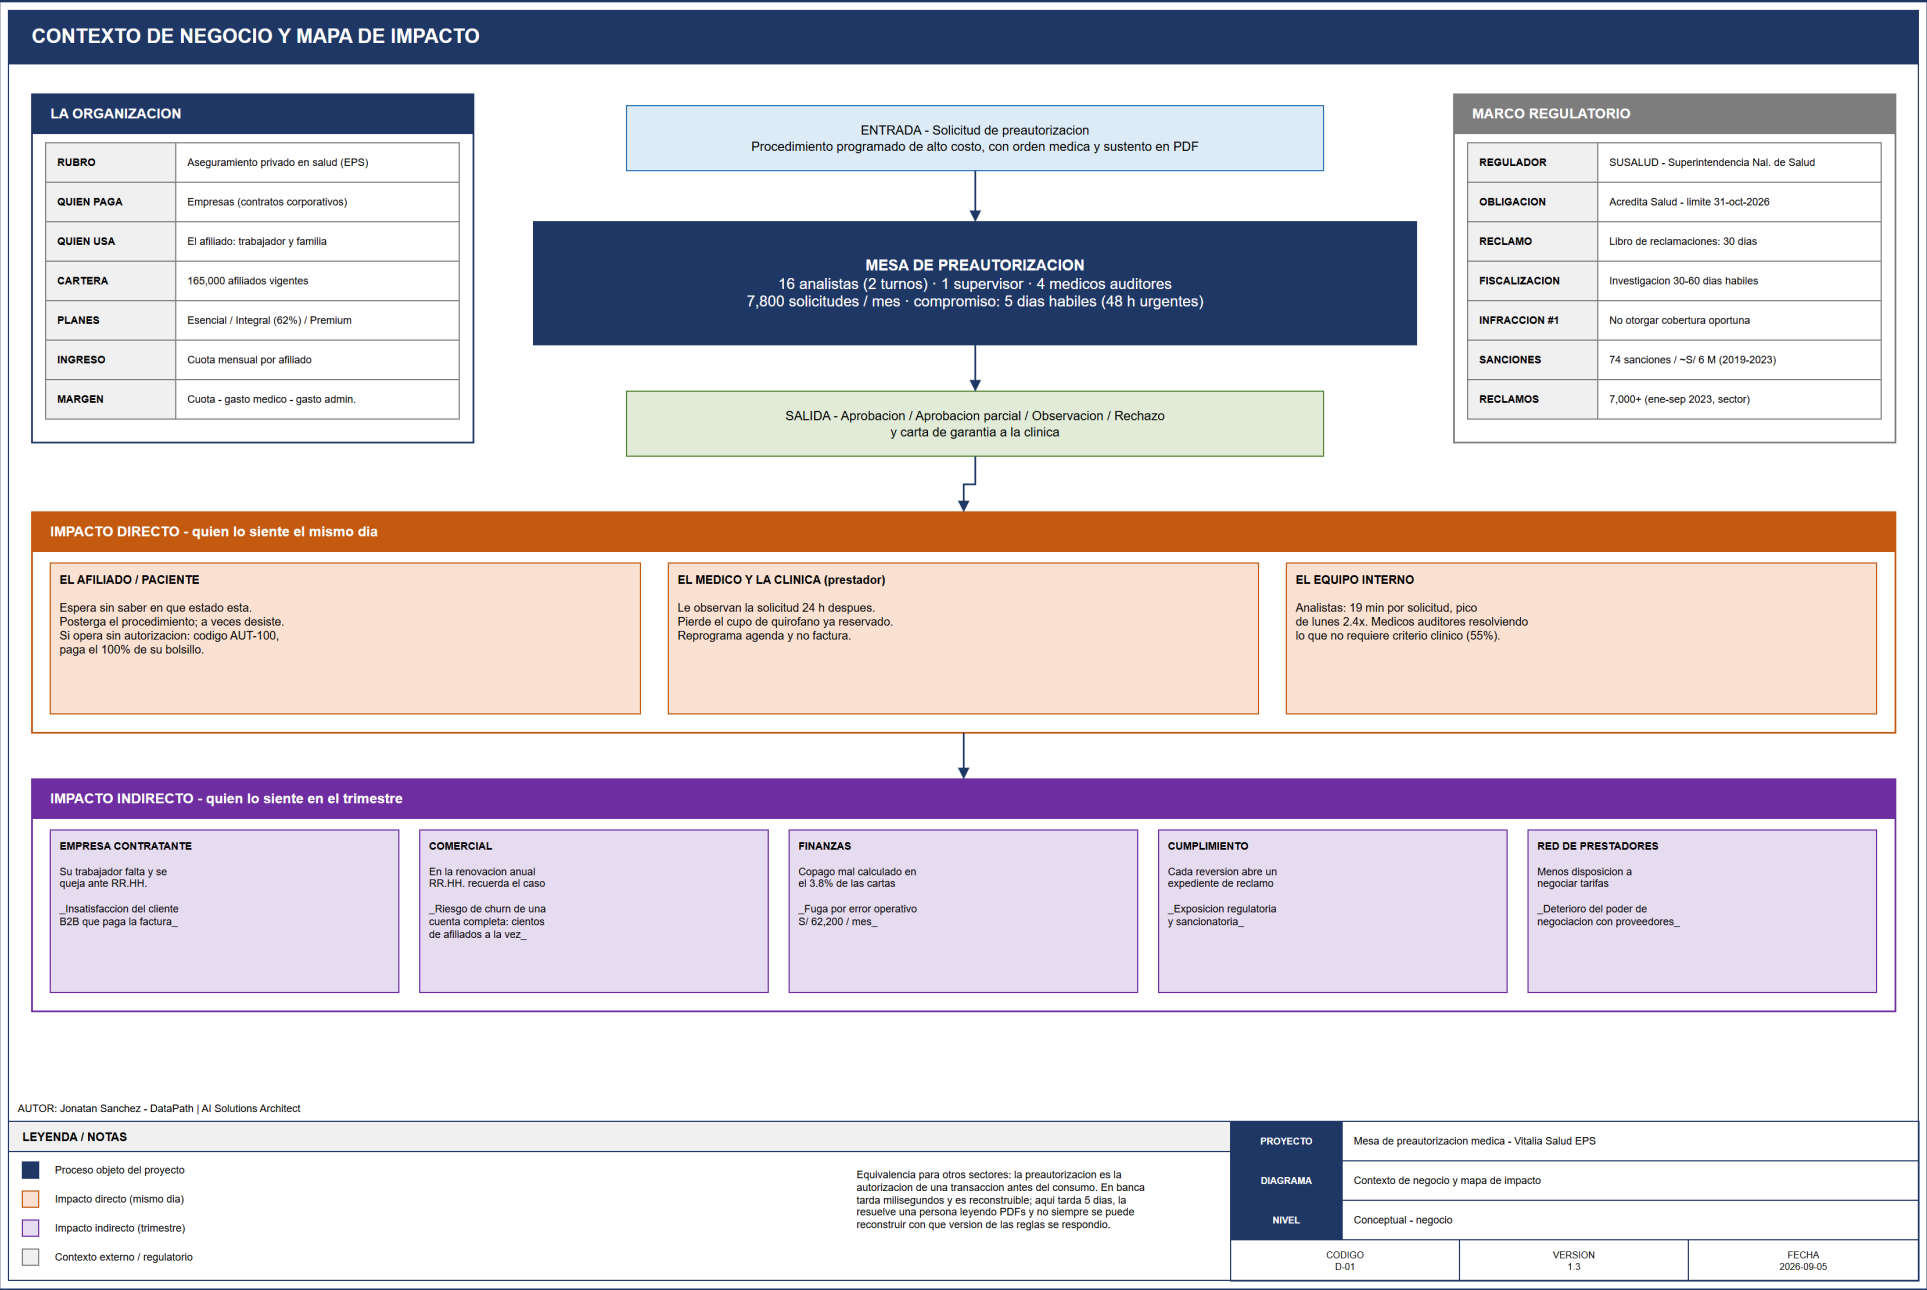
QUIÉN DEPENDE DE ESTA MESA

Directo: el paciente, que espera o desiste · la clínica, que pierde el cupo de quirófano · el equipo interno saturado.

Indirecto: la empresa contratante, comercial —**riesgo de churn de una cuenta entera, cientos de afiliados a la vez**—, finanzas, cumplimiento ante SUSALUD y la red de prestadores.

En banca, cuando pasas la tarjeta, el comercio pregunta *«¿autoriza este consumo, para este cliente, por este monto?»* y la respuesta llega en **milisegundos**, automática y reconstruible.

La **preautorización médica es exactamente esa pregunta**. Aquí demora **cinco días**, la responde una persona leyendo PDFs escaneados, y muchas veces no se puede reconstruir con qué versión de las reglas se respondió.



El analista de la mesa y el médico auditor de Vitalia Salud EPS necesitan **decidir si un procedimiento programado se autoriza y con qué copago**, durante el **proceso de preautorización**, pero hoy cada solicitud recorre **ocho sub-procesos manuales** contra una política que cambia seis veces al año, generando **6.8 días de p95 contra un compromiso contractual de 5 y S/ 235,200 al mes** de costo operativo.

7,800

SOLICITUDES / MES

165 mil

AFILIADOS · 3 PLANES

19 min

DE TOQUE HUMANO · P95 52

16 + 4

ANALISTAS Y MÉDICOS AUDITORES

Compromiso de servicio	Hoy p50	Hoy p95	Meta	
Programados	2.1 d	6.8 d	5 d hábiles	✗
Urgentes	26 h	61 h	48 h	✗
Atención en el extranjero	9 d	—	15 d	✓

ALCANCE DEL PROYECTO

Dentro: preautorización de procedimientos programados, urgentes y en el extranjero — desde que el prestador envía la solicitud hasta que se emite la carta de autorización.

Fuera: emergencias sin preautorización, siniestros hospitalarios, liquidación de reembolsos y el maestro de afiliados, que vive en el core y **no se replica**.

El volumen no está disperso: **el 71% cae en 24 combinaciones de diagnóstico y procedimiento** —un supuesto declarado, no un hecho medido—, y es lo que hace viable automatizar la mayoría sin resolver primero la cola larga.

LOS SIETE DOLORES MEDIDOS · P1–P7

P1 · 23% observadas por expediente incompleto

P2 · 21% derivadas al médico auditor

P3 · 3.8% de error en el copago

P4 · 1.4% de reversiones al apelar

P5 · sin trazabilidad de la versión aplicada

P6 · pico de lunes 2.4× el promedio

P7 · la política cambia ~6 veces al año

Cuatro de los siete no son problemas de velocidad sino de **consistencia**: la misma solicitud puede resolverse distinto según quién la tome y qué versión del manual tenga a mano.

LOS 19 MINUTOS, MINUTO A MINUTO

Recepción y registro del expediente	4 min
Verificación de elegibilidad y vigencia	3 min
Cálculo de carencias, topes y copago	2 min
Búsqueda de la regla en el manual de política	7 min
Emisión de la carta	3 min

El paso más caro no es decidir: es **encontrar contra qué decidir**. Ese solo dato ya orienta dónde entra RAG y dónde no hace falta.

POR QUÉ EL COSTO NO ES ADMINISTRATIVO

En el mercado donde el proceso está mejor medido, **95%** de los médicos reporta que la preautorización retrasa atención necesaria, **79%** que hay pacientes que abandonan el tratamiento y **26%** que derivó en un evento adverso serio.

El costo de una mesa lenta es clínico, no administrativo. Eso cambia qué se optimiza: un diseño que solo minimiza costo por solicitud está optimizando la variable equivocada.


CÓMO RESPONDE EL MERCADO AL MISMO PROBLEMA — Y DE LAS CUATRO, SOLO DOS SON TECNOLÓGICAS

A · Interoperabilidad. HL7 Da Vinci CRD, DTR y PAS: el permiso se pide desde el sistema del médico, con el requisito ya resuelto en el origen.

B · Regulación. CMS-0057-F obliga APIs en 2027 y SB 1120 exige que la IA no decida: firma el médico. Este diseño ya cumple ambas.

C · Gold-carding. Texas HB 3459 exime a los prestadores con buen historial: **ataca el volumen sin tecnología**, y es complementario, no rival.

D · Automatizar. Es la ruta de este proyecto. El precedente muestra su lado peligroso: automatizar la *negación* es lo que hundió a PXDX.



Concepto	AS-IS S/ mes	TO-BE S/ mes	Δ	KPI que lo demuestra
Operación de la mesa	76,600	28,200	-48,400	Touch time 19 → 7 min · STP 55-60%
Retrabajo por observación	11,300	3,700	-7,600	Observadas 23% → ≤ 9%
Auditoría médica	48,000	22,900	-25,100	Derivación 21% → ≤ 10%, ≥85% confirmada
Fuga por copago mal aplicado	62,200	6,600	-55,600	Error de copago 3.8% → ≤ 0.4%
Reclamos por reversión	37,100	18,600	-18,500	Reversiones 1.4% → ≤ 0.7%
Total	235,200	80,000	-155,200	TAT p95 ≤ 2.5 d / ≤ 24 h

CADENA DE VALOR

Potencial = volumen × mejora × valor unitario → **S/ 155,200/mes**

Capturable = potencial × adopción × realización → **S/ 96,600/mes**

Neto = capturable – run → **S/ 74,900/mes ≈ S/ 0.90 M/año**

LOS FACTORES DE CAPTURA, DECLARADOS

Fuga de copago	100%	caja inmediata, no productividad
Reclamos	60%	parte es costo externo real
Mesa + retrabajo	40%	no se despide a nadie: se absorbe crecimiento
Auditoría médica	30%	la capacidad liberada se reinvierte

Los factores son la parte discutible del caso, y por eso van explícitos: el revisor puede bajarlos y rehacer la cuenta.

Y SI EL REVISOR NO LOS CREE

Recortando **cada factor a la mitad**, el capturable cae de S/ 96,600 a ≈ **S/ 48,300/mes**, el neto a S/ 26,600 y el payback pasa de **8.8 a ≈ 25 meses**.

El caso sigue siendo positivo, pero deja de ser evidente. Esa es exactamente la razón de declarar los factores en lugar de esconderlos dentro de un promedio: **la discusión del caso de negocio es sobre la captura de horas, no sobre la tarifa de ningún servicio**.

La diferencia entre los dos escenarios es de gestión del cambio, no de arquitectura — y por eso el Anexo G incluye el plan de reinversión de la capacidad médica liberada.

EL DATO QUE ORDENA TODA LA DISCUSIÓN

El 58% del valor capturable viene de la fuga de copago, y se resuelve con un motor de reglas determinista — sin nada de IA. Es la evidencia numérica de la tesis del proyecto: la IA entra donde queda el problema que solo ella resuelve, no antes.

Las métricas de operación y de IA que acompañan al negocio —latencia p95, disponibilidad, costo por solicitud, *faithfulness*, *recall@k* y tasa de éxito de tarea— nunca se reportan solas: ver el trío de contrapeso en la lámina 06.

Sub-problema	Naturaleza de la necesidad	Ruta elegida	Por qué esa y no otra
Elegibilidad y vigencia	Reglas estables	Software determinista	Es un dato del core consultado por API. Un modelo solo agregaría incertidumbre y costo
Carencias, topes y copago	Reglas estables	Motor de reglas	Es aritmética contractual, y debe dar el mismo resultado siempre. Aquí está el 58% del valor
Lectura del expediente clínico	Extracción de documento	OCR + LLM · Gemini Flash	PDF escaneado y redactado por un tercero: no hay estructura que parsear
Interpretación de la política	Conocimiento privado y trazable	RAG híbrido + rerank	180 páginas que cambian ~6 veces al año y exigen devolver la cita textual vigente
Ruteo y priorización	Clasificación con umbral	Reglas + confianza medida	El umbral de derivación es una decisión de negocio, no una salida del modelo
Subsanación de expedientes	Acciones dinámicas por caso	AGENTE	Único sub-proceso donde el camino sí varía: qué falta, a quién pedírselo y cuántas veces insistir

LA DECISIÓN DE CABECERA · ADR-01

Esto no es un agente. Toda solicitud recorre las mismas seis verificaciones, en el mismo orden, contra la misma política — y su valor está precisamente en que *no* varíe. Un agente aportaría autonomía donde el negocio necesita determinismo, y a cambio traería un camino no reproducible: imposible de sustentar ante SUSALUD.

LA EXCEPCIÓN HONESTA

Agente acotado a la subsanación. Nunca a la decisión de autorizar.

Ese recorte es la decisión de arquitectura más importante del proyecto: no es «no usé agentes», es «**los usé exactamente donde pagan y los prohibí donde no**». Multi-agente se descartó (ADR-04): el analista y el auditor no negocian entre sí — uno escala al otro, que es una transición de estado, no una conversación.

MATRIZ DE DECISION - QUE LLEVA IA Y QUE NO

INSTRUMENTO DE RUTEO - en orden; gana la primera que responde SI

D1 La respuesta ya esta en un sistema, sin ambigüedad?	→SI→	Integracion SIN IA
D2 Se calcula con una formula o una tabla cerrada?	→SI→	Motor de reglas SIN IA
D3 Entrada no estructurada, tarea acotada y salida verificable?	→SI→	LLM dentro de un flujo
D4 Conocimiento propio que cambia y hay que citar la fuente?	→SI→	RAG con cita obligatoria
D5 El camino de resolucion varía por caso, en runtime?	→SI→	Agente
D6 Hay roles con objetivos distintos que deban negociar?	→SI→	Multi-agente
D7 La accion es irreversible, regulada o el error es asimetrico?	→SI→	HITL / gate (se suma)

RUTEO DE LOS OCHO SUB-PROCESOS DE LA MESA

S1	Recibir y normalizar la solicitud .	Integracion convencional	D1
S2	Extraer CIE-10, procedimiento, fecha, clinica 21%	LLM validado contra catalogo	D3
S3	El sustento esta completo? (23% obs.)	Tabla cerrada + verificacion del adjunto	D2+D3
S4	Vigencia, plan, deuda y acumulado 16%	Consulta al sistema central. SIN IA	D1
S5	Cumplio la carencia? 11%	Motor de reglas. SIN IA	D2
S6	Cobertura, exclusion y copago 37%	RAG con cita + motor de copago	D4+V2
S7	Casos limite y criterio clinico (21% der.)	HITL - medico auditor	D7+V1
S8	Emitir carta y carta de garantia 16%	Transaccional + gate de aprobacion	D1+D7

TRES VETOS - pueden tumbar la respuesta anterior

V1 · ASIMETRIA DEL ERROR Cuanto cuesta equivocarse y quien lo paga. Si lo paga el afiliado o el regulador, sube el umbral o entra control humano.	V2 · RECONSTRUIBILIDAD Se puede explicar esta decision seis meses despues, con la politica vigente ese dia? Si no, no sirve aunque acierte.	V3 · ECONOMIA El volumen justifica el costo total? Un sub-problema del 4% del volumen no paga una arquitectura propia.
--	--	---

DECISION DE CABECERA

ESTO ES UN FLUJO ORQUESTADO, NO UN AGENTE Toda solicitud recorre las mismas verificaciones, en el mismo orden, contra la misma politica. Un agente traería camino no reproducible (rompe V2), latencia variable (rompe el SLA de 48 h) y superficie de inyeccion (el expediente lo redacta un tercero).	LA EXCEPCION HONESTA Hay un solo sub-proceso donde el agente si gana según D5: la SUBSANACION (perseguir el documento que falta). Ahí el camino si varia por caso. **El agente persigue documentos. Nunca decide la autorizacion.**
---	--

AUTOR: Jonatan Sanchez - DataPath | AI Solutions Architect

LEYENDA / NOTAS

- Ruta SIN IA: integracion o motor de reglas
- Ruta CON IA: LLM en flujo, RAG o agente
- Control humano (HITL)
- Veto / restriccion que puede revertir la ruta

S4 y S5 concentran el 27% del esfuerzo actual y el 100% de la fuga por copago mal aplicado: el mayor retorno del proyecto viene de la parte que NO lleva IA.

El orden de las preguntas va de lo mas barato, determinista y auditable a lo mas caro, probabilistico y dificil de explicar.

PROYECTO

Mesa de preautorizacion medica - Vitalia Salud EPS

DIAGRAMA

Matriz de decision y ruteo tecnologico

NIVEL

Conceptual - arquitectura

CODIGO
D-03

VERSION
1.3

FECHA
2026-09-05

La pregunta no era «¿en cuál de los ocho pasos entra IA?», sino «¿siguen siendo ocho pasos?» — y la respuesta es no. **Ocho sub-procesos secuenciales pasan a cuatro estados y tres carriles.**

Acción	Qué le pasa al paso de hoy
SE ELIMINA	La revisión de completitud: el formulario bloquea el envío incompleto en el origen. No se automatiza un control — se hace innecesario. Es el patrón DTR de HL7 Da Vinci.
SE ELIMINA	La cola de reparto manual del pico de lunes
SE UNIFICAN	Elegibilidad + carencia + copago + cobertura → E2 · adjudicación unificada , con una parte determinista y una interpretativa que se contrastan entre sí
CAMBIA DE DUEÑO	La consulta de cobertura pasa del analista al prestador: carril 0 · N1 respuesta anticipada , antes de que exista una solicitud
APARECE	Sello de versión de política en cada carta, traza inmutable y agente de subsanación

8 → 4

SUB-PROCESOS → ESTADOS

1.23 → 0.40

TOQUES HUMANOS POR SOLICITUD

19 → 7

MINUTOS DE TOUCH TIME

TRES CARRILES, NO UNO

Carril 0 · N1 — consulta anticipada del prestador, antes de que exista solicitud. Es el carril que ataca el pico de lunes por el lado de la demanda.

Carril 1 — guardrail → E1 extracción → E2 adjudicación → E3 ruteo medido → E4 emisión sellada → traza inmutable.

Carril 2 · N2 — autorización por episodio, **condicional**: bloqueada por un endoso a la póliza. Es una mesa contractual, no una revisión de arquitectura, y por eso es la fase de menor control del equipo técnico.

Los cuatro estados — **E1** extracción → **E2** adjudicación → **E3** ruteo medido → **E4** emisión sellada. Un expediente no puede estar en dos a la vez, y cada transición deja traza inmutable con la versión de política vigente.

Rediseñar antes de automatizar es lo que hace creíble la meta de **55–60% de STP**. Automatizar los ocho pasos de hoy tal como están habría dejado intactos el reparto manual del lunes, el 23% de observaciones y la búsqueda de la regla — es decir, casi todo el problema, con una capa de IA encima.

LO QUE EL REDISEÑO LE EXIGE A LA ORGANIZACIÓN

Un **rol nuevo: curador de política** (0.5 FTE, S/ 6,000/mes), dueño de que cada endoso entre versionado, segmentado y citable. Y un compromiso declarado: **la capacidad médica liberada se reinvierte, no se recorta.**

Sin esas dos cosas el rediseño se revierte solo en el primer trimestre: el manual vuelve a desactualizarse y los auditores vuelven a derivar por defecto. Es la parte del proyecto que no se resuelve con arquitectura.

REDISEÑO DEL PROCESO - DE OCHO SUB-PROCESOS A CUATRO ESTADOS

PROCESO ACTUAL - ocho sub-procesos	ACCION DE REDISEÑO	PROCESO REDISEÑADO
S1 · Recepcion y normalizacion de la solicitud Formulario libre que acepta cualquier cosa	ELIMINAR	La solicitud nace estructurada en N1: el medico elige del catalogo, no escribe texto libre. No hay nada que normalizar
S2 · Extraccion de datos del PDF 4 min de transcripcion manual · 21% del esfuerzo	**REDUCIR ALCANCE**	E1 · EXTRACCION sobrevive solo para documentos clinicos. Los campos administrativos ya vienen capturados desde N1
S3 · Verificacion de sustento completo Se descubre a las 24 h · 23% observaciones	**ELIMINAR EL ESTADO**	"Observacion" deja de ser un estado del expediente y pasa a ser una condicion de envio . No hay carta de observacion
S4 · Vigencia, plan, deuda, acumulado 3 min en dos pantallas	UNIFICAR	E2 · ADJUDICACION UNIFICADA DE POLIZA Una sola evaluacion devuelve elegibilidad + carencia + cobertura + exclusion + copago, con la cita textual de la version vigente. Estaban separados porque eran tres pantallas y tres personas , no porque sean tres decisiones.
S5 · Carencia y preexistencia 2 min de aritmetica manual	UNIFICAR	
S6 · Cobertura, exclusion y copago 7 min buscando en el manual · 37% del esfuerzo	UNIFICAR	
S7 · Casos limite Derivacion defensiva: 55% no requeria criterio clinico	REDISTRIBUIR	E3 · RUTEO MEDIDO lo hace el sistema por umbral, no el analista por miedo. El auditor deja de ser valvula de escape
S8 · Emision de la carta Copiado a mano desde tres pantallas	ABSORBER	En el carril automatico decidir y emitir son el mismo acto . E4 solo es un estado cuando hay firma humana que esperar

LOS PASOS QUE NO EXISTIAN - un rediseño que solo quita pasos es un recorte, no un rediseño

N1 RESPUESTA DE COBERTURA EN EL PUNTO DE LA ORDEN Responde antes de que exista la solicitud, con cita y copago estimado. Lo habilita: que responder cueste centimos y no 7 minutos.	N2 AUTORIZACION POR EPISODIO El esquema oncologico o el plan de terapias, autorizado una vez. Lo habilita: que revalidar la elegibilidad sea gratis.	N3 ESTIMACION DE COSTO AL AFILIADO El copago de bolsillo, antes del procedimiento. Lo habilita: el motor determinista ya calcula el numero.	N4 CURADURIA DE LA POLITICA como proceso continuo Rol nuevo. Cada endoso se publica con version, vigencia y diff. Sin el, no se sostienen R2 ni F4.	N5 EXENCION POR DESEMPEÑO del prestador (gold-carding) Ataca el volumen de entrada, no su costo unitario. Decision del sponsor. El sistema produce el dato; no toma la decision.
---	--	---	---	---

LO QUE SE EVALUO Y SE MANTIENE

Fusionar el guardrail dentro de E1 -> **NO**. Debe correr antes de que el contenido toque un modelo. Fusionar el ruteo (E3) con la adjudicacion (E2) -> **NO**. Consumen insumos distintos. Que el agente absorba el ruteo -> **NO**. Volvería a poner lo no determinista en la decision (veto V1). Eliminar el control humano en casos limite -> **NIUNCA**. Es el invariante R3. Reducir las 8 capas de guardrail -> **NO**. El orden barato->caro ya las hace baratas.

El HITL es el unico paso que se conserva por razones que no son de eficiencia.

EFEECTO SOBRE EL PROCESO

Sub-procesos / estados de negocio	8	4
Toques humanos por solicitud	1.23	0.40
Solicitudes que entran a la mesa	7,800/mes	~6,400/mes
El prestador conoce la respuesta	2 a 7 dias	en el acto

AUTOR: Jonatan Sanchez - DataPath | AI Solutions Architect


LEYENDA / NOTAS


- El paso desaparece del proceso
- El paso se unifica o se absorbe en otro
- El paso se reduce o cambia de dueño
- Capacidad que hoy no existe

Orden del analisis: ELIMINAR -> UNIFICAR -> REORDENAR -> AUTOMATIZAR.
Automatizar primero congela el desperdicio.

Lo que rediseña el proceso no es la IA: es que el costo marginal de una decision calga de 19 minutos a segundos. La IA es lo que hace que calga. Analisis completo en 04a_rediseño_del_proceso.md

PROYECTO	Mesa de preautorizacion medica - Vitalia Salud EPS		
DIAGRAMA	Rediseño del proceso (ESIA)		
NIVEL	Logico - proceso		
CODIGO D-10	VERSION 1.3	FECHA 2026-09-05	





Decisión	Problema que resuelve	Alternativa descartada	Trade-off que introduce	Cómo se valida
Flujo orquestado, no agente ADR-01	Camino no reproducible ⇒ negación indefendible ante SUSALUD (veto V2)	Agente autónomo de punta a punta	Menos flexibilidad ante casos raros: van al auditor	100% de decisiones reconstruibles a 6 meses
RAG sobre corpus versionado ADR-02, ADR-03	La política cambia ~6 veces/año y hay que citar la versión vigente	<i>Fine-tuning</i> (no cita fuente) y política completa en el prompt (no cabe)	Latencia de recuperación y un pipeline de indexación que mantener	<i>faithfulness</i> ≥ 0.95 · <i>recall@k</i> · 30 casos de regresión por endoso
Búsqueda híbrida + rerank ADR-06	Los códigos de procedimiento son identificadores, no lenguaje natural	Búsqueda densa sola	Dos índices y un reordenador más en la ruta crítica	Medido: 0.56 densa sola vs. 0.74 — por eso se adoptó
Colección por versión de política ADR-21	Citar política derogada es el peor error posible (R2)	Una colección con filtro por version_id	~700 MB con 12 versiones vivas y publicación por alias	Un filtro olvidado cita derogada; una colección equivocada no existe
HITL obligatorio ADR-07, ADR-10	Asimetría del error: negar mal un caso oncológico no es un bug (veto V1)	Automatizar el 100% sin control humano	El STP se topa en 55–60%, no en 90%	0% de negaciones sin firma médica — invariante, no meta

LOS TRES INVARIANTES DE DISEÑO Y LOS TRES VETOS

R1 · lo determinista nunca pasa por un modelo — R2 · ninguna afirmación sobre política sin cita textual de la versión vigente — R3 · ninguna negación por necesidad médica sin firma de médico colegiado.

Vetos: **V1** asimetría del error · **V2** reconstruibilidad · **V3** economía. Seis de los 21 ADRs tienen como condición de reversión la palabra **nunca**: son exactamente los que sostienen R2, R3 y V1. Si alguno se revierte, lo que cambia no es el diseño, es la promesa regulatoria.

PATRONES ADOPTADOS Y DESCARTADOS

chunking por cláusula

hybrid search

rerank

sentence-window

single agent + HITL

retry · circuit breaker · fallback

idempotencia

DLQ

GraphRAG

multi-agente

RAPTOR

fine-tuning

GraphRAG queda en el roadmap: aportaría solo en exclusiones con excepción encadenada, y las relaciones plan–cobertura ya son tablas del core.

La restricción que ordena todo lo demás: **el sistema automático puede autorizar o escalar; no puede negar por necesidad médica**. No es una regla de negocio — es la ausencia de la transición en el catálogo de herramientas. **Un atacante que convenza al modelo de «negar este caso» no consigue una negación: consigue un escalamiento al auditor.**

GUARDRAIL DE ENTRADA · 8 CAPAS, DE BARATA A CARA

La primera que bloquea corta la cadena. Política **fail-close**.

- 1 secretos · regex <1 ms
- 2 inyección
- 3 toxicidad
- 4 regex propio
- 5 PII · Presidio local
- 6 URL
- 7 Prompt Guard 2 · ~120 ms
- 8 Llama Guard 4 · ~400 ms

Decisiones: **PERMITIR · TRANSFORMAR · CONFIRMAR · BLOQUEAR**. Separación instrucción/dato y esquema JSON cerrado: el modelo no tiene nada interesante que hacer aunque obedezca al atacante.

GUARDRAIL DE SALIDA · O1–O6

El que casi nadie escribe. **O1** cita literal verificada contra el corpus firmado · **O2** vigencia · **O3** **contraste del copago determinista** ↔ **prosa** · **O4** sin negación sin firma · **O5** sin PII · **O6** esquema y catálogo. O3 es la justificación retroactiva de haber partido E2 en dos: si la aritmética y la redacción no coinciden, la carta no sale.

AMENAZAS MODELADAS · A1–A10 Y EL CONTROL QUE LAS CONTIENE

A1 Inyección indirecta en el documento del prestador	capa 2 + separación instrucción/dato
A2 Texto invisible y homóglifos	normalización + capa 4
A3 Exfiltración por la respuesta	O5 + esquema JSON cerrado
A4 Envenenamiento del corpus normativo	corpus firmado · ingesta con doble aprobación
A5 Cita de política derogada	colección por versión (ADR-21) + O2
A6 Ruptura de R3: negación sin firma	la transición no existe + O4
A7 DoS económico	cuota por prestador · Cloud Armor · tope por solicitud
A8 Abuso del canal del agente	catálogo cerrado + tope de reintentos
A9 Fuga por el log	enmascarado antes de trazar
A10 Secretos dentro del expediente	capa 1, antes de cualquier modelo

Datos de salud bajo **Ley 29733**, con residencia declarada y enmascarado antes de la extracción.

GOLDEN SET · 430 CASOS

300 expedientes (210 del núcleo / 90 de la cola) + 60 preguntas de política + 40 adversariales + 30 de regresión por endoso. **Doble anotación ciega con κ de Cohen ≥ 0.75** : si $\kappa < 0.75$ el problema no es el modelo, es que el criterio humano no está definido. +25 casos/mes desde producción.

RED TEAMING · R1–R16

Agrupados por invariante atacado. Criterio de aprobación: **100% en invariantes**, $\geq 95\%$ en el resto. **R11 · forzar una negación automática: imposible por construcción.**

EL TRÍO QUE SE REPORTA SIEMPRE JUNTO

% de automatización (STP)	55–60%
% de reversiones al apelar	$\leq 0.7\%$
% de negaciones sin firma médica	0% · invariante

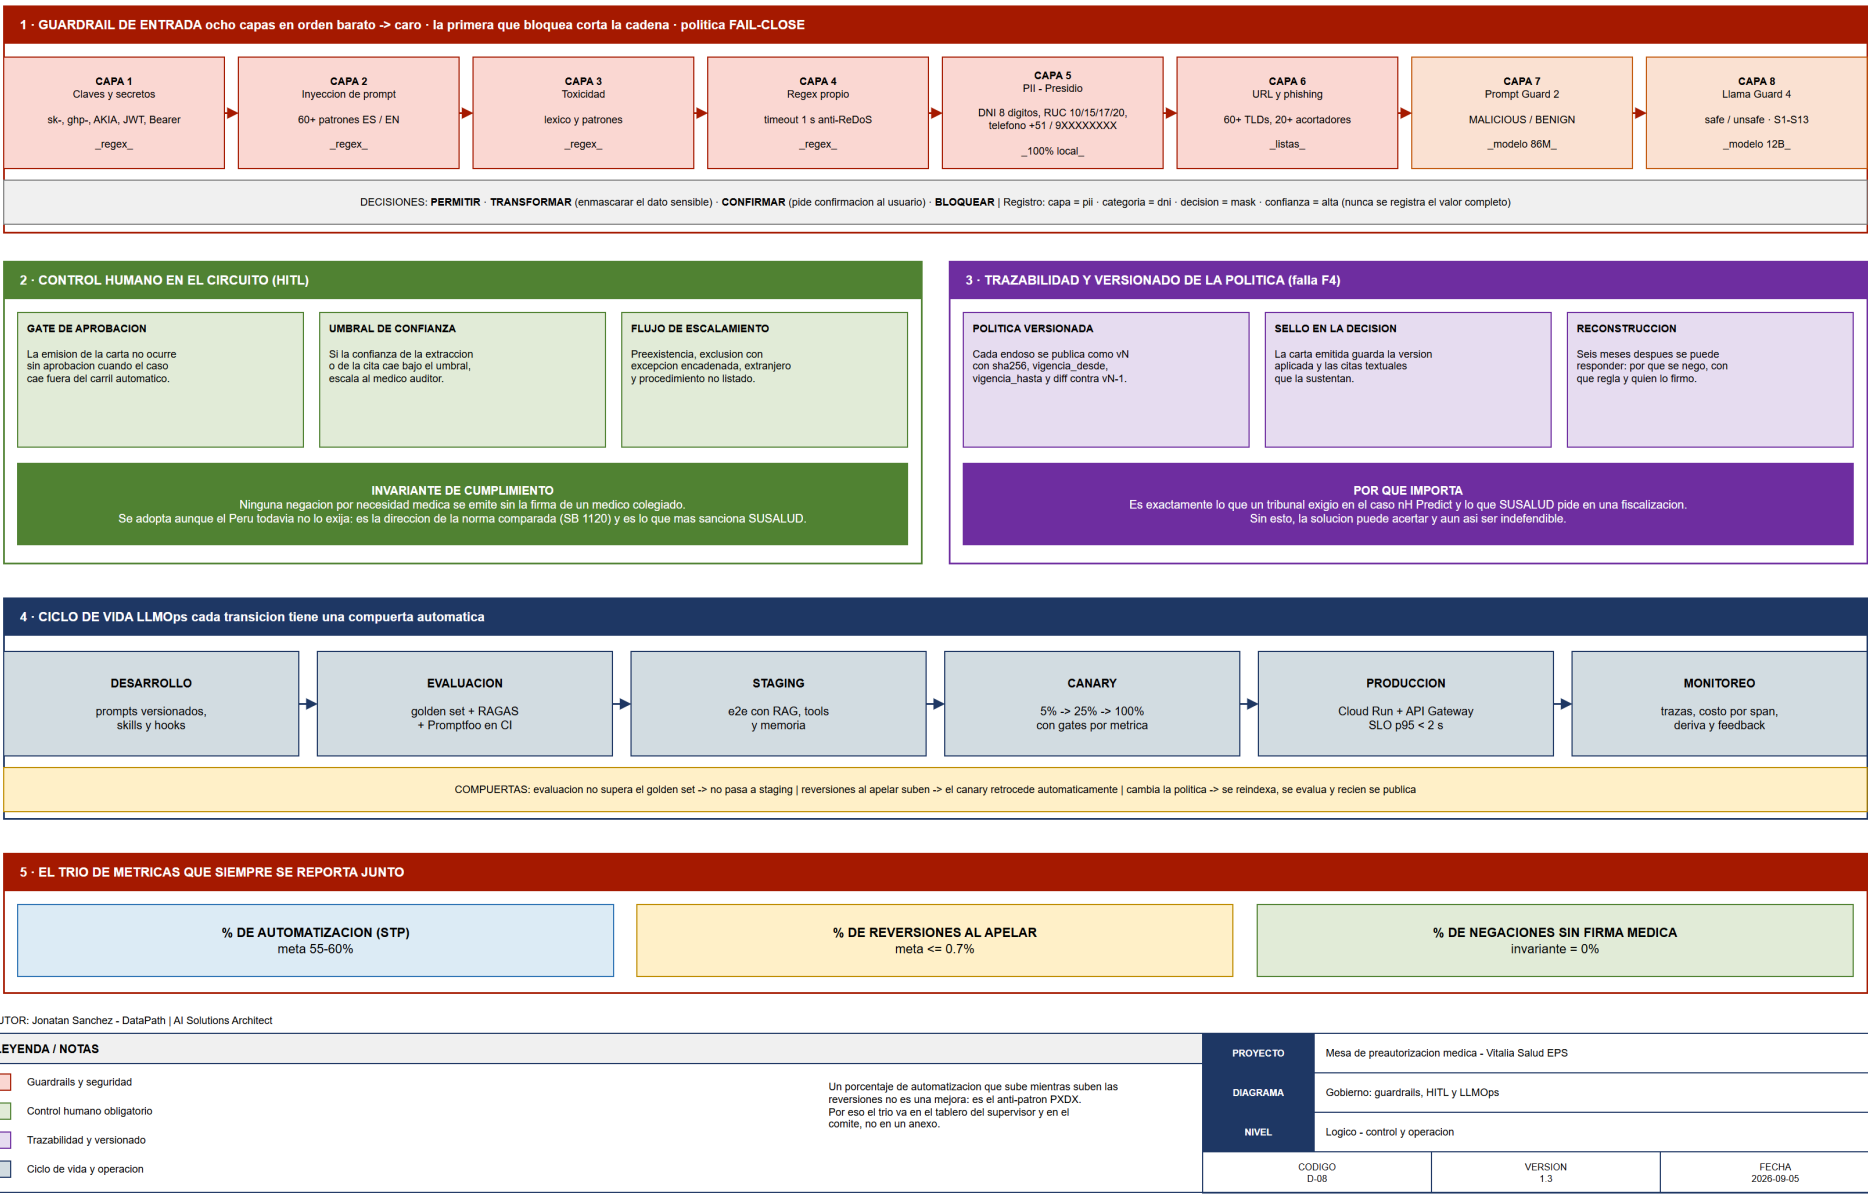
Un STP que sube mientras suben las reversiones no es una mejora: es el anti-patrón que hundi3 a PXDX —300,000 casos en dos meses, 1.2 segundos por caso— y el que le costó a nH Predict una demanda colectiva. Por eso el trío va en el tablero del supervisor, no en un anexo.

Y LAS MÉTRICAS POR COMPONENTE, DEBAJO

Recuperación · política	<i>recall@k</i> y precisión de la cita
Extracción del expediente	exactitud por campo · cobertura
Adjudicación	<i>faithfulness</i> ≥ 0.95 · acuerdo con el auditor
Guardrail	FPR $\leq 0.5\%$ · fugas = 0
Agente de subsanación	tasa de éxito de tarea · reintentos por caso

Ninguna de estas cinco se presenta al negocio por sí sola: solo explican **por qué** el trío de arriba se mueve. **ADR-08 a ADR-12** registran las cinco decisiones de seguridad y qué haría falta para revertirlas.

GOBIERNO DE LA SOLUCION - GUARDRAILS, CONTROL HUMANO Y LLMOps



S/ 6,700

FACTURA CLOUD / MES · BOTTOM-UP

S/ 0.86

CLOUD POR SOLICITUD · 8% DEL COSTO DEL PROCESO

75 / 25

FIJO VS. VARIABLE

3.8%

DE LA FACTURA SON TOKENS DE LLM

FINOPS · DÓNDE ESTÁ LA PALANCA REAL

Si el volumen se duplica, la factura sube **25%** y el unitario cae a S/ 0.52. Cambiar Flash por Pro sube **23%**. Optimizar el prompt a la mitad de tokens baja **1.9%**: no vale el esfuerzo. **La palanca son min-instances, el dimensionamiento de Qdrant y Neon, y la retención de logs** — no los prompts. Costo atribuido por solicitud, por prompt y por tipo en cada *span*.


SLOS · EL COMPROMISO ES SOBRE EL PROCESO, NO SOBRE LA AUTOMATIZACIÓN

J1 · consulta anticipada N1	p95 < 2 s · 99.5%
J3 · adjudicación	p95 < 90 s
J4 · extremo a extremo	p95 < 5 min
J5 · emisión de la carta	p95 < 10 s · 99.9%
J7 / J8 · TAT de negocio	≤ 2.5 d · ≤ 24 h

Error budget 3.6 h/mes con política de cuatro escalones. Groq no publica SLA: por eso la disponibilidad se argumenta como **compuesta** y honestamente.

RESILIENCIA Y DEGRADACIÓN · N0–N5

Timeout escalonado, reintento con *jitter* solo en operaciones idempotentes, *circuit breaker* por dependencia, *bulkhead*, clave de idempotencia solicitud + versión + sha256, Pub/Sub con DLQ. **Regla transversal: ante un incidente se baja de nivel de automatización, nunca se relaja un control.** Toda degradación termina en el mismo lugar — la mesa, que no desaparece. N4 = *fail-close*.



D-14 · T1–T11 Y EL PRESUPUESTO DE LATENCIA P95: 8 · 25 · 6 · 30 · 5 S + 16 DE HOLGURA

GO-LIVE · 10 COMPUERTAS

Golden set superado · red team 100% en invariantes · corpus firmado y versionado · canary 5→25→100% con *gates* por métrica · runbook I1–I6 · seis alertas con dueño · RPO 5 min en Neon y **RPO 0 en Qdrant** (el índice es derivado) · prueba de recuperación semestral.

S/ 660 K

INVERSIÓN TOTAL

S/ 96,600

CAPTURABLE / MES

8.8 meses

PAYBACK · 8.6 CON EL COSTEO BOTTOM-UP

S/ 1.13 M

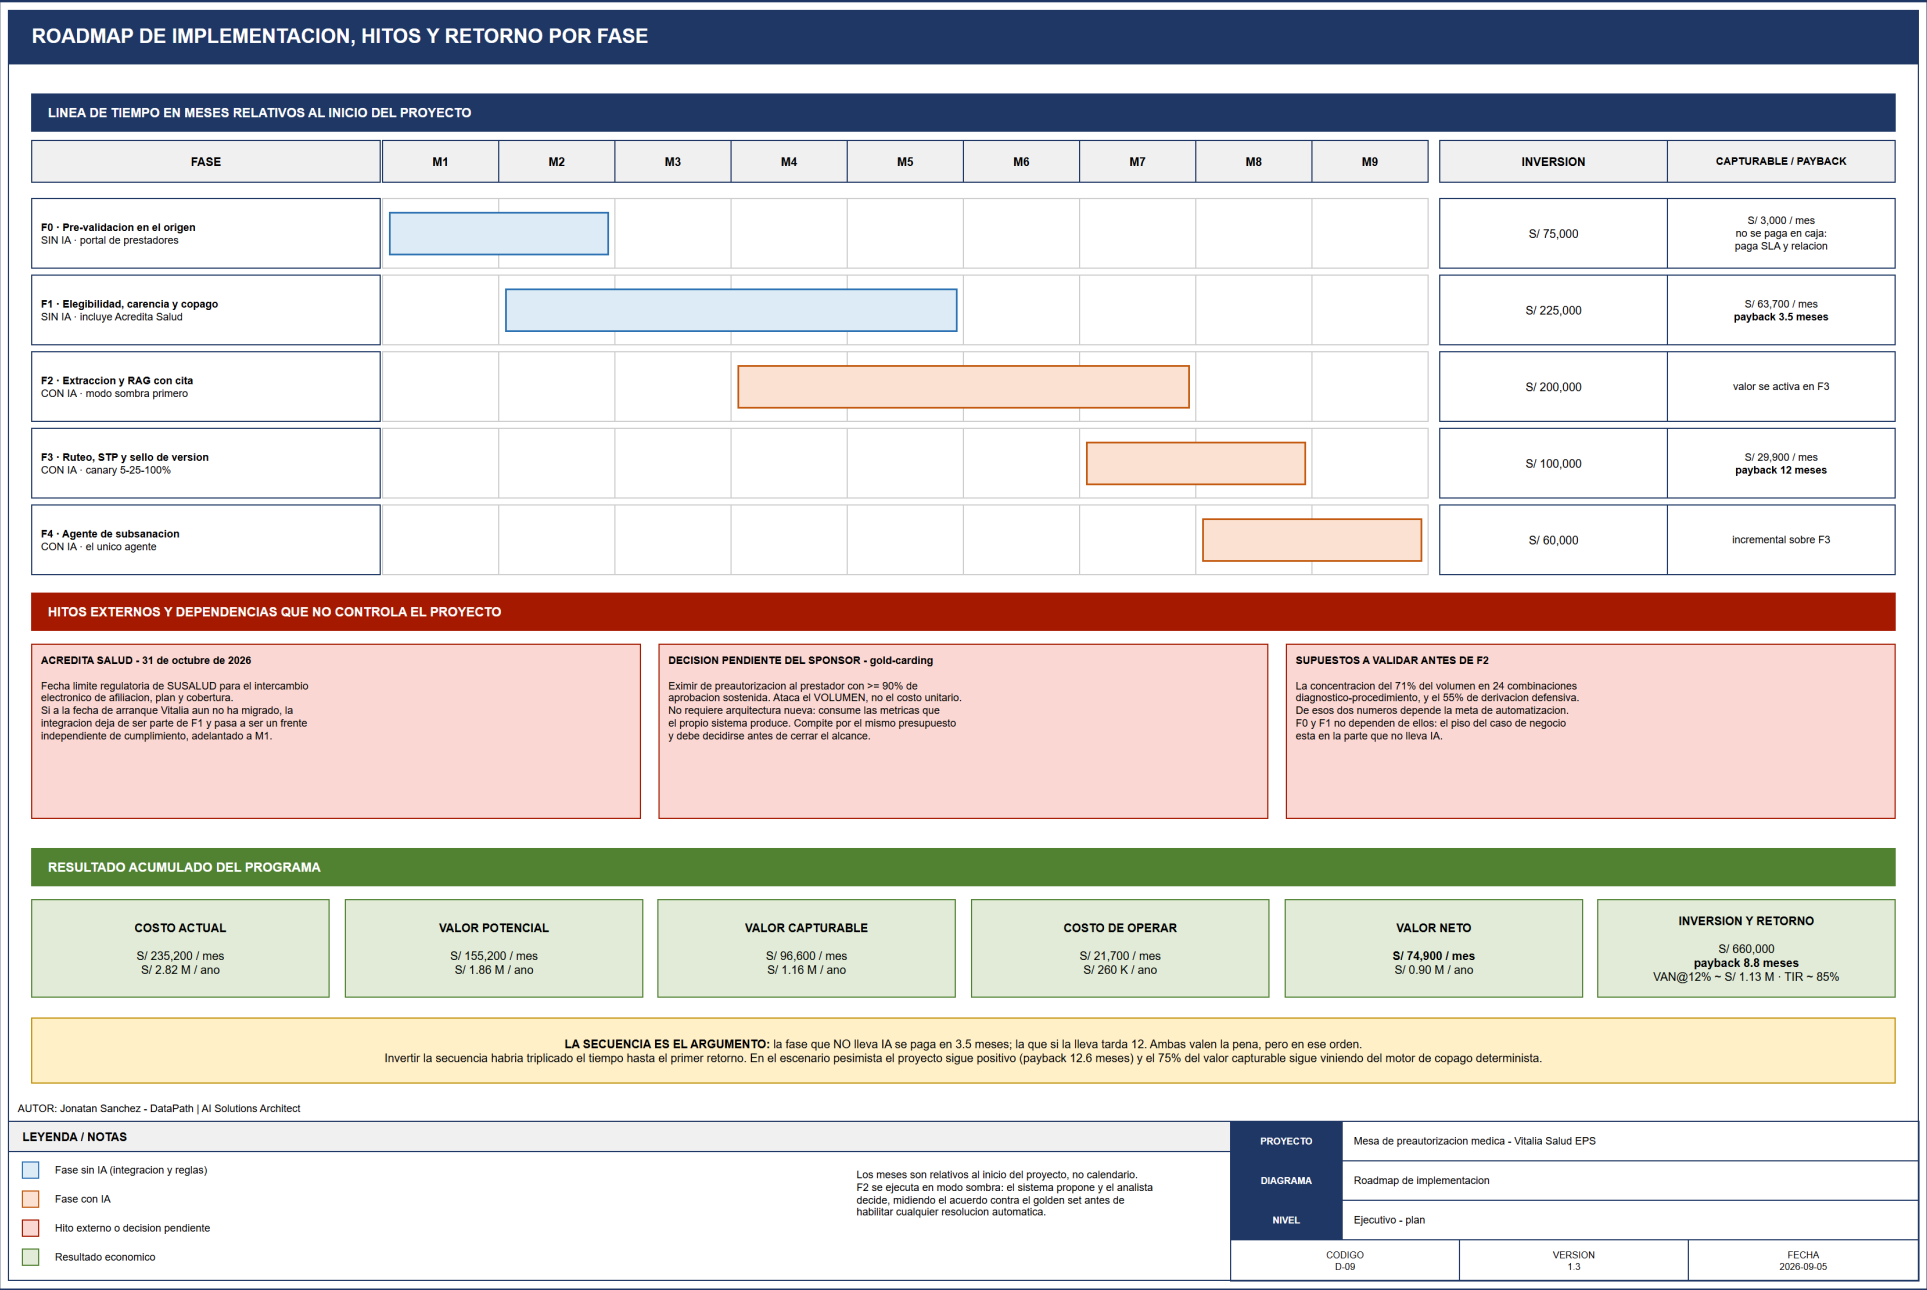
VAN @12% A 3 AÑOS · TIR ≈ 85%

Fase	Qué entrega	Duración	Inversión	Capturable/mes	Payback
F0 · pre-validación en el origen sin IA	Observadas 23% → 9%. El formulario bloquea el envío incompleto: no se automatiza el control, se hace innecesario. Si el proyecto parara aquí, ya se pagó en SLA	~4 sem	75,000	3,000	no paga en caja
F1 · elegibilidad, carencia y copago sin IA	Cierra la fuga de copago con reglas deterministas · integra Acredita Salud · deja lista la precondition de N2	~8 sem	225,000	63,700	3.5 meses
F2–F4 · extracción, RAG, STP y agente con IA	STP 55–60%, cita trazable y subsanación. Modo sombra primero, canary 5 → 25 → 100% después, con compuertas por métrica	~22 sem	360,000	29,900	12 meses
F5 · autorización por episodio condicional	Bloqueada por el endoso a la póliza — decisión contractual, no técnica. No se compromete valor sobre ella	~6 sem	—	holgura	—

Lo que hay que decir en voz alta: la fase que **no** lleva IA se paga en 3.5 meses; la que sí la lleva tarda 12. Ambas valen la pena, pero en ese orden — invertir la secuencia habría triplicado el tiempo hasta el primer retorno.


RIESGOS VIVOS Y HECHOS DECLARADOS

Hito externo innegociable: integración con Acredita Salud al **31-oct-2026** · El riesgo del proyecto está en el **factor de captura de horas**, no en la tarifa de ningún servicio: la factura cloud completa es el 7% del valor capturable y puede triplicarse sin voltear el caso · F5, la fase de mayor retorno por solicitud, es la de menor control del equipo técnico.



D-09 Qué mirar: la IA no aparece hasta F2, y el hito externo de Acredita Salud (31-oct-2026) cae dentro de F1 — es la única fecha que el proyecto no puede mover

Anexo H



Anexo	Contenido	Documento
A	Detalle de costos y assumptions	05a_costeo_cloud.md
B	Arquitectura física/cloud y networking	D-11 · 04_to_be.md §3
C	Modelo de datos, pipeline y metadata	08_modelo_de_datos.md · D-13
D	ADRs y alternativas evaluadas 21 ADRs	02 §3–§4 · 06 §12 · 07 §12 · 08 §11
E	Golden set, evals y red-team cases	06_seguridad_y_evaluacion.md
F	Sizing, load test, SLOs y observabilidad	07_operacion_y_produccion.md · D-14
G	Rediseño del proceso y gestión del cambio	04a · 04 §6 · D-10
H	Riesgos y mitigaciones	04_to_be.md §9
I	Auditoría del baseline	05_caso_de_negocio.md §8
J	Benchmark de mercado y precedentes	03_benchmark_mercado.md

LO QUE ESTÁ DECLARADO COMO SUPUESTO, NO COMO HECHO

La concentración del **71%** del volumen en 24 combinaciones · el **55%** de derivación defensiva · los tres drivers del costeo (8 páginas por expediente, 45% al RAG, dimensionamiento de Qdrant y Neon) · $\kappa \geq 0.75$ entre anotadores y el umbral de confianza 0.90 · y el más apalancado de todos: el **hit rate del caché semántico**, que sostiene las 3,500 consultas RAG/mes del modelo de costos.
Un revisor debe poder señalar cada uno sin encontrar una defensa inventada.

FASE 2 — MVP DEMOSTRABLE

Implementación en Google Cloud de los servicios destacados, corrida del golden set, pruebas de carga P1–P7 y captura de trazas. Se adjuntará como **anexo de evidencia** sobre este mismo diseño, sin modificar lo comprometido aquí.

Este proyecto no automatiza una mesa: **rediseña un proceso** y coloca IA únicamente donde una solución más simple no alcanza.

Por eso las dos primeras fases **no llevan IA**, el 58% del valor lo captura un motor de reglas, y la decisión de arquitectura de la que más orgullo se puede tener es **una que prohíbe: el sistema no puede negar.**