

PROYECTO FINAL · FASE 2 · ANEXO DE EVIDENCIA

Anexo K · El MVP funcionando

Vitalia Salud EPS · mesa de preautorización de procedimientos programados
La interfaz final y los servicios de las diez sesiones, corriendo

Ses.	Servicio que se demuestra	Dónde vive en el MVP	Estado
S01	Enrutamiento por complejidad: la tarea elige el modelo	comun/router_modelos.py	✓ cerrada
S02	Caché semántico de clave determinista y costo por span	comun/cache_semantico.py · pantalla 5	✓ cerrada
S03	kind + Helm + Ollama como motor de degradación N3	—	pendiente
S04	Ingesta: 11 docs → cláusula → sha256 + versión → alias	ingesta/pipeline_politica.py	✓ cerrada
S05	Qdrant Cloud, HNSW, texto literal en el payload	comun/recuperacion.py	parcial
S06	RAG con cita textual verificada · guardrail O1–O6	flujo/ · guardrails/salida.py	parcial
S07	El único agente: subsanación. Servidor MCP propio, 4 tools	mcp_vitalia/	✓ cerrada
S08	Skills versionadas y seis ganchos como middleware	mcp_vitalia/ganchos.py · skills/	✓ cerrada
S09	Guardrail de 8 capas + red team R01–R16, y Model Armor medido contra él	guardrails/entrada.py · model_armor.py	✓ cerrada
S10	Costo por span, latencias p50/p95 y feedback loop	metrica_costo en Neon · pantalla 5	parcial

16/16

ATAQUES DETECTADOS
0 FALSOS POSITIVOS

5/5

CITAS VERIFICADAS
CARÁCTER POR CARÁCTER

112

FRAGMENTOS DE POLÍTICA
SEGMENTADOS POR CLÁUSULA

40%

ACIERTOS DE CACHE
0 FALSOS ACIERTOS


EL ORDEN DE TRABAJO FUE EL INVERSO

El riesgo de esta fase era construir un chatbot RAG bonito que demostrase dos sesiones de diez. Por eso **primero se escribió el mapa de evidencias y después el código**: si una sesión no tenía fila, no estaba demostrada.


LO QUE PRODUJO LA CORRIDA

7,524 líneas de Python en 8 paquetes · 7 suites de prueba con **0 fallos** · 15 archivos de evidencia · 7 capturas · y **21 defectos encontrados y corregidos**, cada uno con su porqué escrito.


El más incómodo: **ningún umbral de similitud es seguro por sí solo** para decidir un acierto de caché — las reformulaciones legítimas miden 0.598–0.787 y una pregunta de otra cobertura mide 0.780.




1 · INGRESO #/INGRESO



2 · CONSULTA ANTICIPADA #/N1/AF-100234



3 · BANDEJA #/BANDEJA



5 · PANEL DE OPERACIÓN #/PANEL

2 · EL CARRIL QUE EVITA LA COLA

Respuesta **desde caché: US\$ 0.000000**, con la cláusula citada y **verificada literal** contra el corpus vigente. Es el **41% del volumen** que hoy entra a la mesa sin necesidad de entrar.

3 · UN SOLO RELOJ PARA TODOS

Cuatro expedientes con la ruta que decidió el motor determinista en E3 — automática, subsanación, mesa, mesa— y el semáforo del SLA **calculado en la base**, no en cada pantalla.

5 · LO QUE CUESTA Y LO QUE FALLA

Costo por solicitud, hit-rate del caché, p50/p95 por tramo, guardrail de entrada y de salida, feedback y la **versión de política vigente**. S02 y S10 en la misma vista.

Falta la pantalla 4, el detalle del expediente. Tiene tres variantes y es la que se enseña en la defensa: va sola en la lámina siguiente.

Vitalia Salud EPS

Mesa de preautorización · MVP

Ingreso

Consulta anticipada

Bandeja

Expediente

Panel de operación

Ana Lucía Cavero Bendezú

mesa

hitl

política v2026_09

Cesárea programada · PRC-5901 · 082.0 · Parto por cesárea electiva · VIT-INT · SOL-450ee590fdef

LO DETERMINISTA · EL MOTOR DECIDE

sin modelo

reproducible

R1

Elegibilidad

activo

Carencia

no cumplida

220 días de 300 exigidos

Cobertura

no_cubierto

carencia de maternidad no cumplida: exige 300 días y el afiliado tiene 220

Copago

—

Esta columna no pasó por ningún modelo. La fila de `metrica_costo` del tramo `adjudicacion` vale **US\$ 0.000000**, y esa fila en cero es la prueba—no un hueco en los datos.

LO INTERPRETATIVO · EL MODELO LEE

gpt-4o-mini

propone, no dispone

CAMPO	VALOR	CONF.	CONTRASTE
afiliado_ref	AF-100512	1.00	catálogo ✓
prestador_id	PRE-0077	1.00	catálogo ✓
dx_cie10	082.0	1.00	catálogo ✓
procedimiento_codigo	PRC-5901	1.00	catálogo ✓
tipo	programado	1.00	catálogo ✓
documentos	["orden_medica", "informe_medico", "ecografia_obstetrica", "control_prenatal"]	1.00	catálogo ✓

La confianza que declara el modelo **no decide nada**: se guarda para la traza. Lo que decide es la columna «contraste», que es una consulta al catálogo. Un modelo seguro de un código inexistente sigue estando equivocado.

FUNDAMENTO · LAS CLÁUSULAS QUE SOSTIENEN LA DECISIÓN

«la cobertura de maternidad tiene un periodo de carencia de 300 días calendario contados desde el inicio de vigencia. Esto significa que el parto queda cubierto si ocurre a partir del día 301»

carencias_y_preexistencias-v2026_09-c03 · Carencia de maternidad ·

verificada literal

GUARDRAIL DE SALIDA · LOS SEIS CONTROLES

CONTROL	QUÉ VERIFICA	RESULTADO
01 ✓	La cita existe literalmente	las 1 citas coinciden carácter por carácter
02 ✓	La versión citada estaba vigente	todas las citas son de v2026_09, vigente el 2026-09-05
03 ✓	Consistencia determinista → prosa	el motor no calculó copago y la carta no afirma ninguno
04 ✓	Sin negación clínica sin firma	no es una negación por necesidad médica

05

✓

Sin PII fuera de destino

destino es el titular: la carta lleva sus datos por diseño

06

✓

Esquema y catálogo

2 código(s), las fuentes declaradas y los fundamentos del motor resuelven contra el corpus vigente

Los seis corren siempre y completos, aunque uno ya haya fallado: quien audita tiene que ver todo lo que estaba mal de una sola vez.

BORRADOR DE CARTA

aprobada por el guardrail

gpt-4o

todavía no es de nadie

Estinada Ana Lucía Cavero Bendezú,

Esperamos que se encuentre bien. Nos dirigimos a usted en relación con la solicitud de preautorización para el procedimiento de cesárea programada (PRC-5901) bajo el diagnóstico 082.0.

Lamentamos informarle que, conforme a la política vigente, no podemos autorizar la cobertura de este procedimiento en este momento. La razón es que la carencia de maternidad no ha sido cumplida. Según nuestras políticas, «la cobertura de maternidad tiene un periodo de carencia de 300 días calendario contados desde el inicio de vigencia. Esto significa que el parto queda cubierto si ocurre a partir del día 301». Actualmente, usted ha cumplido 220 días de carencia, por lo que aún no se alcanza el periodo requerido.

Entendemos que esta situación puede ser inconveniente y le recomendamos considerar otras opciones disponibles para la atención del parto. Si tiene

Emitir sin cambios

Emitir con mis correcciones

Editar el texto **no salta el guardrail**: los seis controles vuelven a correr sobre lo que usted apruebe. Se puede vencer al borrador—que solo dice que el sistema no emite esto por su cuenta—, no a O1-O6.

BITÁCORA · APPEND-ONLY

recibida → E1 · sistema

extracción validada contra catálogo (gpt-4o-mini)

2026-09-05T23:37:21.403334+00:00

E1 → E2 · motor-determinista

carencia de maternidad no cumplida: exige 300 días y el afiliado tiene 220

2026-09-05T23:37:21.403334+00:00

E2 → E3 · motor-determinista

carencia no cumplida: el sistema no emite la negación, escala con la cita y el borrador

2026-09-05T23:37:21.403334+00:00

E3 → hitl · motor-determinista

carencia no cumplida: el sistema no emite la negación, escala con la cita y el borrador

2026-09-05T23:37:21.403334+00:00

En naranja, lo que movió una persona.

COSTO DEL EXPEDIENTE

TRAMO	MODELO	TOKENS	US\$	MS
extraccion	gpt-4o-mini	420/159	0.000158	2004
adjudicacion	—	0/0	0.000000	120
emision	gpt-4o	1097/239	0.005132	1810
Total			0.005291	

ARRIBA · LO DETERMINISTA Y LO INTERPRETATIVO · EL FUNDAMENTO CITADO · LOS SEIS CONTROLES

ABAJO · EL BORRADOR DE CARTA SIN EMITIR · LA BITÁCORA APPEND-ONLY · EL COSTO DEL EXPEDIENTE

#expediente/SOL-450ee590fdef Qué mirar: **carencia no cumplida, 220 días de 300** · la columna determinista con **US\$ 0.000000** · la cita verificada · los seis controles en verde · y el estado **hitl**

Anexo K §K.2.1

Inv.	Cómo se comprueba, sin creerle a nadie
R1	El tramo adjudicacion de metrica_costo tiene modelo = NULL, 0 tokens y US\$ 0.000000 en las cuatro solicitudes. Al lado, extraccion.modelo = gpt-4o-mini. La asimetría está en el dato.
R2	O1 exige al menos una cita y la compara carácter por carácter; O2 comprueba que la versión citada estaba vigente. En el Carril 0, el control sin_cita sustituye la respuesta sin cita por la frase SIN_CLÁUSULA.
R3	Es una restricción de base de datos, no una validación de aplicación: CHECK (tipo <> 'niega_necesidad_medica' OR firma_id IS NOT NULL)
V1	El caché no lee ni escribe cuando no puede clasificar la pregunta. Prefiere no responder a responder de otra cobertura.
V2	Tres comandos rehacen el estado entero y las siete capturas desde una base vacía — y el destino se cambia con VITALIA_BASE, así que se rehacen igual contra Cloud Run.
V3	El guardrail de entrada cortocircuita en la primera capa que bloquea: no se paga Groq si una regex ya decidió. Y las 4 entradas legítimas dan 0 falsos positivos.

ADR-10 EN LA SUPERFICIE DE HERRAMIENTAS

El servidor MCP expone cuatro tools. No hay ninguna que emita una carta, que niegue, ni que cambie el estado de un expediente. No están restringidas por permisos: no están escritas. Un agente conectado ahí puede leerlo todo, calcular cualquier cosa y redactar una subsanación — y no tiene forma de resolver una solicitud.

Y LO QUE EL MVP NO DEMUESTRA

Sin integración con el core · sin firma digital real · sin Identity Platform · sin Acredita Salud. Volumen de demostración, no las 7,800 solicitudes/mes. S03, S05, S06 y S10 siguen parciales o pendientes, y están listadas una a una. La URL de Cloud Run no es pública: la política de organización rechaza allUsers, y la excepción no depende del proyecto. Model Armor se activó y se midió: 11 de 16 ataques frente a 16 de las capas propias.

El MVP no demuestra que el sistema sea capaz de decidir. Demuestra lo contrario, que es lo que este diseño vino a sostener.

En la pantalla 4a hay una carta de negación escrita, controlada y sin emitir, esperando a una persona. La máquina de estados no tiene ninguna transición que la saque de ahí sin que alguien firme.