

PROYECTO FINAL · FASE 2 · ANEXO K · ÁLBUM DE CAPTURAS

La ruta de pantalla y la configuración que la sostiene

Vitalia Salud EPS · mesa de preautorización de procedimientos programados
Veintiún capturas a página completa, cada una con lo que hay que mirar en ella

Este álbum es el acompañante visual del **Anexo K**. El anexo explica qué se construyó; aquí se ve. **Parte 1** recorre la aplicación pantalla por pantalla, en el mismo orden en que se recorre en la defensa. **Parte 2** abre las consolas de los servicios que la sostienen —Qdrant, Neon, Cloud Run, Cloud Build, Cloud Storage, Secret Manager, Model Armor y Groq— para que lo que la aplicación afirma se pueda contrastar contra el proveedor que lo ejecuta.

AUTOR
Jonatan Sánchez

PARTE 1 · APLICACIÓN
7 capturas · 10 páginas

PROYECTO GCP
datapath-labs-202608 · us-central1

PROGRAMA
DataPath · AI Solutions Architect · 2026-08

PARTE 2 · CONFIGURACIÓN
14 capturas · 14 páginas

SERVICIO
Cloud Run · vitalia-mesa

FECHA
2026-09-06

POLÍTICA VIGENTE
v2026_09 · 112 fragmentos

RELACIÓN CON LA FASE 1
Se suma a los anexos A–J

Una página por captura, la imagen a tamaño completo y encima —no debajo— **qué hay que mirar en ella**. Las tres pantallas del expediente son largas: ocupan dos páginas cada una, arriba y abajo, para que el texto siga siendo legible en papel. Ninguna captura se ha recortado ni retocado.

PARTE 1 · LA RUTA DE PANTALLA

#	Pantalla	Ruta	Lo que prueba
P1	Ingreso	#/ingreso	La autenticación es del borde, no de la aplicación (ADR-15) — y está dicho en la propia pantalla
P2	Consulta anticipada N1	#/n1/<pregunta>	El Carril 0: respuesta desde caché, US\$ 0.000000 y la cita verificada literal (R2)
P3	Bandeja	#/bandeja	Cuatro expedientes, su ruta y el reloj del SLA calculado en la base
P4a	Expediente · pendiente	#/expediente/SOL-450ee590fdef	La pantalla de la defensa: negación redactada, controlada y sin emitir (ADR-10)
P4b	Expediente · emitido	#/expediente/SOL-689ce3eab0e9	El ciclo cerrado: carta, folio del core y bitácora completa
P4c	Expediente · subsanación	#/expediente/SOL-13f58ae117e3	El único agente del diseño: pide lo que falta en vez de rechazar
P5	Panel de operación	#/panel	Costo, hit-rate, p50/p95 por span, ruteo, guardrail y versión de política

Cada captura es una URL. La interfaz enruta por *hash*, así que cualquiera reabre exactamente la misma pantalla sin reproducir una secuencia de clics que nadie anotó. Es el veto **V2** aplicado a la evidencia: *una captura que no se puede rehacer no es evidencia*. Los identificadores SOL-... cambian en cada repoblado y *demo/capturar.py* no lleva ninguno escrito: los resuelve por estado.

PARTE 2 · LA CONFIGURACIÓN TÉCNICA

#	Consola	Objeto	Sesión
C01–C02	Qdrant Cloud	vitalia_politica_v2026_09 + alias · vitalia_cache_semantico	S05 · S02
C03–C06	Neon · esquema vitalia_mvp	adjudicacion · politica_version · borrador_carta · metrica_costo	S04 · S06 · S10
C07–C08	GCP · Cloud Run	vitalia-mesa: revisión, variables y observabilidad	S10
C09–C10	GCP · Cloud Build / Storage	Historial de compilaciones y bucket de contexto	S10 · S04
C11	GCP · Secret Manager	Los cinco secretos vitalia-*	S08
C12–C13	GCP · Seguridad · Model Armor	Plantilla vitalia-preauth y sus detecciones	S09
C14	Groq	Consumo del mes: US\$ 0.06	S01 · S09

UNA REGLA QUE SE CUMPLE EN LAS VEINTIUNA

Ninguna captura muestra el valor de una clave. En Secret Manager se ven *nombres*; en Cloud Run, *referencias montadas* (Secreto: vitalia-openai-api-key:latest). Ni la URL del clúster de Qdrant ni la cadena de conexión de Neon aparecen en ninguna imagen. Eso no es prudencia decorativa: la captura tiene que poder circular con el entregable.

PARTE 1 DE 2

La ruta de pantalla

Siete capturas en el orden del recorrido: se entra, se pregunta, se abre la bandeja, se trabajan los tres expedientes que cubren los tres desenlaces del diseño —autorización automática, subsanación y escalamiento a la mesa— y se cierra en el panel de operación.


La pantalla que hay que enseñar es la 4a. Es la única que pone en la misma página, y en dos columnas contiguas, las dos naturalezas que el diseño se negó a mezclar: lo determinista, que no pasa por ningún modelo, y lo interpretativo, que propone pero no dispone.

El modelo propone, el catálogo dispone.

La puerta. Se elige perfil —analista, auditor médico u operación— y se entra a la bandeja. Lo que hay que mirar no es el formulario: es la advertencia que la propia pantalla lleva escrita.

- **La autenticación es del borde, no de la aplicación** (ADR-15). En producción la resuelve Identity Platform delante de Cloud Run; la aplicación nunca guarda contraseñas ni emite sesiones.
- En el MVP el ingreso es **de demostración**, y así lo dice la pantalla. Se declara en vez de simularse: un control que se aparenta es peor que uno que falta, porque nadie lo va a buscar después.
- El perfil elegido gobierna lo que se ve y lo que se puede hacer aguas abajo — el botón de emitir no existe para quien no puede emitir.

Ruta reproducible: `http://127.0.0.1:8088/app/#/ingreso`



P1_INGRESO.PNG · 1440 × 900 · FASE2/EVIDENCIAS/PANTALLAS/

El carril que lleva el 41% del volumen y que en el proceso actual consume tiempo de analista sin producir ninguna decisión: preguntas de cobertura y carencia que se responden antes de radicar nada.

- **Servida desde caché:** la etiqueta desde_caché, US\$ 0.000000 y coseno 1.0000. La clave del caché es determinista —versión, plan, cobertura, intención— y no una similitud: *ningún umbral de similitud es seguro por sí solo* (hallazgo E00 §1).
- **La cita se muestra, no se resume:** carencias_y_preexistencias-v2026_09-c03, verificada carácter por carácter contra el corpus vigente. Es **R2** en vivo — ninguna afirmación sobre política sin cita textual.
- El caché guarda las citas junto a la respuesta. *El caché no puede tirar las citas:* una respuesta barata sin respaldo sería exactamente el error que el diseño no admite.

Vitalia Salud EPS

Mesa de preautorización · MVP

Ingreso

Consulta anticipada

Bandeja4

Expediente

Panel de operación

política v2026_09
neon ✓ · qdrant ✓ (112 fragmentos)

Consulta anticipada

El prestador pregunta **antes** de mandar el expediente. Es el carril que evita que una solicitud incompleta entre a la cola.

PREGUNTAR

Consulta

¿Cuántos días de carencia tiene la cesárea programada en el plan VIT-INT?

Plan del afiliado

— sin especificar —

Consultar

☒ usar caché semántico

Sugerencias: [documentos](#) · [REEM-06](#) · [un ataque](#)

RESPUESTA

desde caché

2251 ms

US\$ 0.000000

coseno 1.0000

La cesárea programada se cubre bajo la cobertura de maternidad, la cual tiene un periodo de carencia de 300 días calendario contados desde el inicio de vigencia. «La cobertura de maternidad tiene un periodo de carencia de 300 días calendario contados desde el inicio de vigencia.»
FUENTES: [carencias_y_preexistencias-v2026_09-c03]

CITAS VERIFICADAS CONTRA EL CORPUS

«La cobertura de maternidad tiene un periodo de carencia de 300 días calendario contados desde el inicio de vigencia.»

carencias_y_preexistencias-v2026_09-c03 · Carencia de maternidad

Desglose · guardrail 757 ms · caché 1494 ms · recuperación 0 ms · generación 0 ms

P2_CONSULTA_N1.PNG · 1440 × 700 · PREGUNTA: «¿CUÁNTOS DÍAS DE CARENIA TIENE LA CESÁREA PROGRAMADA EN EL PLAN VIT-INT?»

Vitalia Salud EPS · Anexo K · Álbum de capturas · Parte 1

Jonatan Sánchez · DataPath · 2026-09-06 · pág. 5

- Lo primero que ve un analista al empezar el turno. Cuatro expedientes, y para cada uno tres datos que en el proceso actual viven en tres sitios distintos: la **ruta** que tomó (automática · subsanación · mesa · mesa), el **estado** y el **reloj del SLA**.
- El reloj **se calcula en la base de datos**, no en el navegador: un solo reloj para todos los analistas, y el mismo que audita después la operación. El TAT deja de depender de quién mira la pantalla.
 - La ruta no es una etiqueta puesta a mano: es el resultado de E3, y la columna motivo_ruta de adjudicacion guarda por qué se tomó.
 - Dos de los cuatro están en la mesa. **Eso es el diseño funcionando**, no una carencia: el sistema escala lo que no debe resolver solo.

Vitalia Salud EPS

Mesa de preautorización · MVP

Ingreso

Consulta anticipada

Bandeja4

Expediente

Panel de operación

política v2026_09

neon ✓ · qdrant ✓ (112 fragmentos)

Bandeja de la mesa

El ruteo lo decidió el motor determinista en E3. El semáforo de la última columna es el reloj del SLA, calculado en la base: un solo reloj para todos los analistas.

POR ESTADO

hitl · 2 agente · 1 emitida · 1

EXPEDIENTES

EXPEDIENTE	AFILIADO	PROCEDIMIENTO	RUTA	ESTADO	COPAGO	SLA
SOL-689ce3eab0e9	Rosa Milagros Quispe Ayala AF-100234 · VIT-INT	Colecistectomía laparoscópica PRC-4712 · K80.2	automática	emitida	S/ 1,210.00	120 h
SOL-13f58ae117e3	Carlos Alberto Ramos Tíneo AF-100777 · VIT-ESE	Artroscopia de rodilla PRC-2933 · M23.2	subsanación	agente	S/ 1,660.00	120 h
SOL-450ee590fdef	Ana Lucía Caveró Bendezú AF-100512 · VIT-INT	Cesárea programada PRC-5901 · O82.0	mesa	hitl	—	120 h
SOL-a470a2ee5065	Víctor Hugo Paredes Lino AF-101010 · VIT-INT	Hernioplastia inguinal con malla PRC-1180 · K40.9	mesa	hitl	—	120 h

INGRESAR UNA SOLICITUD NUEVA

Pega el correo del prestador tal como llegó. E1 lo lee, el motor adjudica y E3 lo rutea. Si el mismo texto ya entró, devuelve el mismo expediente sin volver a pagar los modelos.

De: admisiones@clinica.pe

Asunto: Solicitud de preautorización...

Procesar

P3_BANDEJA.PNG · 1440 × 1000 · EL ESTADO EXACTO ESTÁ EN E14_BANDEJA_DE_LA_DEMO.JSON

Vitalia Salud EPS · Anexo K · Álbum de capturas · Parte 1

Jonatan Sánchez · DataPath · 2026-09-06 · pág. 6

Cesárea programada con **220 días de los 300 de carencia** exigidos. El sistema redactó la negación, la aprobó por el guardrail y **no la emitió**. La mitad superior de la pantalla pone las dos naturalezas del problema en dos columnas contiguas, que es la decisión de diseño que sostiene todo lo demás:

- Izquierda, lo determinista.** Etiquetas sin modelo · reproducible · R1. Elegibilidad, carencia, cobertura y copago con su desglose. Al pie: *«esta columna no pasó por ningún modelo; la fila de métrica_costo del tramo adjudicacion vale US\$ 0.000000, y esa fila en cero es la prueba —no un hueco en los datos»*.
- Derecha, lo interpretativo.** Etiqueta gpt-4o-mini y la advertencia *«propone, no dispone»*. Cada campo extraído lleva su confianza **y** su contraste contra catálogo. La confianza que declara el modelo no decide nada: decide la columna «contraste», que es una consulta.

R1 no se afirma: se lee en el dato. extraccion.modelo = gpt-4o-mini frente a adjudicacion.modelo = NULL, determinista = true. Quien audite no tiene que crearle a la documentación.

Vitalia Salud EPS

Mesa de preautorización · MVP

Ingreso

Consulta anticipada

Bandeja4

Expediente

Panel de operación

Ana Lucía Cavero Bendezú

mesa

hitl

política v2026_09

Cesárea programada · PRC-5901 · O82.0 · Parto por cesárea electiva · VIT-INT · SOL-450ee590fdef

LO DETERMINISTA · EL MOTOR DECIDE

sin modelo reproducible R1

Elegibilidad activo

Carencia no cumplida220 días de 300 exigidos

Cobertura no_cubierto
carencia de maternidad no cumplida: exige 300 días y el afiliado tiene 220

Copago —

Esta columna no pasó por ningún modelo. La fila de métrica_costo del tramo adjudicacion vale **US\$ 0.000000**, y esa fila en cero es la prueba —no un hueco en los datos.

LO INTERPRETATIVO · EL MODELO LEE

gpt-4o-mini propone, no dispone

CAMPO	VALOR	CONF.	CONTRASTE
afiliado_ref	AF-100512	1.00	catálogo ✓
prestador_id	PRE-0077	1.00	catálogo ✓
dx_cie10	O82.0	1.00	catálogo ✓
procedimiento_codigo	PRC-5901	1.00	catálogo ✓
tipo	programado	1.00	catálogo ✓
documentos	["orden_medica", "informe_medico", "ecografia_obstetrica", "control_prenatal"]	1.00	catálogo ✓

La confianza que declara el modelo **no decide nada**: se guarda para la traza. Lo que decide es la columna «contraste», que es una consulta al catálogo. Un modelo seguro de un código inexistente sigue estando equivocado.

FUNDAMENTO · LAS CLÁUSULAS QUE SOSTIENEN LA DECISIÓN

«la cobertura de maternidad tiene un periodo de carencia de 300 días calendario contados desde el inicio de vigencia. Esto significa que el parto queda cubierto si ocurre a partir del día 301»

carencias_y_preexistencias-v2026_09-c03 · Carencia de maternidad · verificada literal

GUARDRAIL DE SALIDA · LOS SEIS CONTROLES

CONTROL	QUÉ VERIFICA	RESULTADO
O1 ✓	La cita existe literalmente	las 1 citas coinciden carácter por carácter
O2 ✓	La versión citada estaba vigente	todas las citas son de v2026_09, vigente el 2026-09-05
O3 ✓	Consistencia determinista → prosa	el motor no calculó copago y la carta no afirma ninguno
O4 ✓	Sin negación clínica sin firma	no es una negación por necesidad médica

P4A_EXPEDIENTE_PENDIENTE.PNG · 1440 × 2150 · MITAD SUPERIOR

La mitad inferior es donde la decisión se vuelve auditable, en este orden:

- **Las cláusulas que la sostienen**, con su chunk_id y la etiqueta **verificada literal**. No un resumen de la política: el texto de la política.
- **Los seis controles O1–O6** del guardrail de salida, con lo que verificó cada uno y su resultado. O1 exige al menos una cita y la compara carácter por carácter; O2 comprueba que la versión citada sea la vigente. En una corrida anterior O1 se cumplía por vacuidad —«*las 0 citas coinciden*»— y ese defecto está escrito en E01_hallazgos_carri11.md.
- **El borrador de carta**, marcado «*todavía no es de nadie*», con dos botones —*Emitir sin cambios* / *Emitir con mis correcciones*— y la advertencia de que **editar el texto no salta el guardrail**.
- **La bitácora append-only**, con cada transición, su actor y su motivo.

Esto es el ADR-10. El expediente está en hitl y la máquina de estados no tiene ninguna transición que lo saque de ahí sin que una persona firme. En la superficie MCP no existe herramienta que emita, niegue o cambie estado: no está restringida, **no está escrita**.

O4 ✓	Sin negación clínica sin firma	no es una negación por necesidad médica
O5 ✓	Sin PII fuera de destino	destino es el titular: la carta lleva sus datos por diseño
O6 ✓	Esquema y catálogo	2 código(s), las fuentes declaradas y los fundamentos del motor resuelven contra el corpus vigente

Los seis corren siempre y completos, aunque uno ya haya fallado: quien audita tiene que ver todo lo que estaba mal de una sola vez.

BORRADOR DE CARTA

aprobada por el guardrail

gpt-4o

todavía no es de nadie

Estimada Ana Lucía Caveró Bendezú,

Esperamos que se encuentre bien. Nos dirigimos a usted en relación con la solicitud de preautorización para el procedimiento de cesárea programada (PRC-5901) bajo el diagnóstico 082.0.

Lamentamos informarle que, conforme a la política vigente, no podemos autorizar la cobertura de este procedimiento en este momento. La razón es que la carencia de maternidad no ha sido cumplida. Según nuestras políticas, «la cobertura de maternidad tiene un periodo de carencia de 300 días calendario contados desde el inicio de vigencia. Esto significa que el parto queda cubierto si ocurre a partir del día 301». Actualmente, usted ha cumplido 220 días de carencia, por lo que aún no se alcanza el periodo requerido.

Entendemos que esta situación puede ser inconveniente y le recomendamos considerar otras opciones disponibles para la atención del parto. Si tiene

Emitir sin cambios

Emitir con mis correcciones

Editar el texto **no salta el guardrail**: los seis controles vuelven a correr sobre lo que usted apruebe. Se puede vencer al borrador —que solo dice que el sistema no emite esto por su cuenta—, no a O1–O6.

BITÁCORA · APPEND-ONLY

- **recibida → E1 · sistema**
extracción validada contra catálogo (gpt-4o-mini)
2026-09-05T23:37:21.403334+00:00
 - **E1 → E2 · motor-determinista**
carencia de maternidad no cumplida: exige 300 días y el afiliado tiene 220
2026-09-05T23:37:21.403334+00:00
 - **E2 → E3 · motor-determinista**
carencia no cumplida: el sistema no emite la negación, escala con la cita y el borrador
2026-09-05T23:37:21.403334+00:00
 - **E3 → hitl · motor-determinista**
carencia no cumplida: el sistema no emite la negación, escala con la cita y el borrador
2026-09-05T23:37:21.403334+00:00
- En naranja, lo que movió una persona.

COSTO DEL EXPEDIENTE

TRAMO	MODELO	TOKENS	US\$	MS
extraccion	gpt-4o-mini	420/159	0.000158	2004
adjudicacion	-	0/0	0.000000	120
emision	gpt-4o	1097/239	0.005132	1810
Total			0.005291	

El caso que **sí** se resuelve solo: elegible, carencia cumplida, cobertura clara y tarifa en catálogo. La mitad superior enseña las mismas dos columnas de P4a, pero con el desenlace contrario.

- **Copago S/ 1,210.00 con su desglose** calculado del tarifario, no estimado por un modelo. La misma columna determinista, el mismo US\$ 0.000000 en el tramo de adjudicación.
- **Carta autoriza emitida** y el **folio del core** devuelto. El sistema no administra el core: lo lee y le entrega (ADR-18).
- La automatización no es el objetivo declarado del diseño, es la consecuencia de haber acotado bien lo determinista: cuando las cuatro condiciones se cumplen, no hay nada que interpretar.

Vitalia Salud EPS

Mesa de preautorización · MVP

Ingreso

Consulta anticipada

Bandeja4

Expediente

Panel de operación

Rosa Milagros Quispe Ayala

automáticaemitidapolítica v2026_09

Colecistectomía laparoscópica · PRC-4712 · K80.2 · Cálculo de la vesícula biliar sin colecistitis · VIT-INT · SOL-689ce3eab0e9

LO DETERMINISTA · EL MOTOR DECIDE

sin modelo

reproducible

RI

Elegibilidad

activo

Carencia

cumplida

427 días de 60 exigidos

Cobertura

cubierto

elegible, sin carencia pendiente y dentro del tarifario del plan

Copago

S/ 1,210.00

DESGLOSE

regla

deducible pendiente + coaseguro sobre el saldo

tarifa

S/ 12,800.00

coaseguro

S/ 610.00

deducible

S/ 600.00

coaseguro pct

5 %

base coaseguro

S/ 12,200.00

Esta columna no pasó por ningún modelo. La fila de `metrica_costo` del tramo adjudicacion vale **US\$ 0.000000**, y esa fila en cero es la prueba —no un hueco en los datos.

LO INTERPRETATIVO · EL MODELO LEE

gpt-4o-mini

propone, no dispone

CAMPO

VALOR

CONF.

CONTRASTE

afiliado_ref

AF-100234

1.00

catálogo ✓

prestador_id

PRE-0031

1.00

catálogo ✓

dx_cie10

K80.2

1.00

catálogo ✓

procedimiento_codigo

PRC-4712

1.00

catálogo ✓

tipo

programado

1.00

catálogo ✓

documentos

["orden_medica", "informe_medico", "ecografia_abdominal"]

1.00

catálogo ✓

La confianza que declara el modelo **no decide nada**: se guarda para la traza. Lo que decide es la columna «contraste», que es una consulta al catálogo. Un modelo seguro de un código inexistente sigue estando equivocado.

FUNDAMENTO · LAS CLÁUSULAS QUE SOSTIENEN LA DECISIÓN

«| Hospitalización y cirugía | 60 días | Los tres planes |»

carencias_y_preexistencias-v2026_09-c02 · Tabla de carencias por cobertura · verificada literal

P4B_EXPEDIENTE_EMITIDO.PNG · 1440 × 2100 · MITAD SUPERIOR

Vitalia Salud EPS · Anexo K · Álbum de capturas · Parte 1

Jonatan Sánchez · DataPath · 2026-09-06 · pág. 9

- Abajo está la **traza entera**, que es lo que convierte una autorización automática en algo defendible ante un regulador:
- **La bitácora recibida → ... → emitida, *append-only***, con actor y motivo en cada transición. No hay UPDATE sobre el estado: hay eventos. Reconstruir el expediente a cualquier fecha es leer la tabla, no reinterpretarla (veto **V2**).
 - **Los controles O1–O6 aplicados también a la carta que se emitió**: emitir sin cambios no salta el guardrail, y emitir con correcciones tampoco.
 - **Las cláusulas citadas** con su versión. Si mañana se publica v2026_10, esta carta seguirá diciendo contra qué versión se decidió.

CARTA EMITIDA

autoriza

CAR-0dfa281a2f88

folio FOLIO-04dbbbe85331

v2026_09

Estimada Rosa Milagros Quispe Ayala,

Nos complace informarle que su solicitud para el procedimiento de colecistectomía laparoscópica ha sido autorizada. Según nuestra revisión, usted cumple con todos los requisitos necesarios: su afiliación está activa, ha superado el periodo de carencia de 60 días requerido para hospitalización y cirugía, y el procedimiento está cubierto dentro del tarifario de su plan VIT-INT. Tal como se indica en la tabla de carencias, «| Hospitalización y cirugía | 60 días | Los tres planes |».

El copago correspondiente a este procedimiento es de S/ 1 210.00. Le recordamos que, conforme a su plan, el deducible anual ya ha sido aplicado, y no se le cobrará nuevamente en este año póliza.

Si tiene alguna pregunta o necesita más información, no dude en contactarnos. Estamos aquí para ayudarle.

Atentamente,

Vitalia Salud EPS

FUENTES: carencias_y_preexistencias-v2026_09-c02, deducibles_y_copagos-v2026_09-c06

BITÁCORA · APPEND-ONLY

- **recibida → E1 · sistema**
extracción validada contra catálogo (gpt-4o-mini)
2026-09-05T23:36:59.808223+00:00
- **E1 → E2 · motor-determinista**
elegible, sin carencia pendiente y dentro del tarifario del plan
2026-09-05T23:36:59.808223+00:00
- **E2 → E3 · motor-determinista**
determinista completo, sin juicio clínico pendiente
2026-09-05T23:36:59.808223+00:00
- **E3 → auto · motor-determinista**
determinista completo, sin juicio clínico pendiente
2026-09-05T23:36:59.808223+00:00
- **auto → E4 · sistema**
carta «autoriza» redactada y controlada
2026-09-05T23:36:59.808223+00:00
- **E4 → emitida · sistema**
carta CAR-0dfa281a2f88
2026-09-05T23:36:59.808223+00:00

En naranja, lo que movió una persona.

COSTO DEL EXPEDIENTE

TRAMO	MODELO	TOKENS	US\$	MS
extraccion	gpt-4o-mini	441/158	0.000161	1957
adjudicacion	—	0/0	0.000000	119
emision	gpt-4o	1528/233	0.006150	2022
Total			0.006311	

P4B_EXPEDIENTE_EMITIDO.PNG · MITAD INFERIOR

Falta el informe médico que sustenta la indicación. En el proceso actual eso termina en un rechazo administrativo que el afiliado vuelve a presentar dos semanas después. Aquí **el sistema pide lo que falta**.

- **Es el único agente del diseño**, y es agente por una razón concreta: no se sabe de antemano cuántos documentos faltan ni cuál pedir primero. Todo lo demás del flujo es determinista o es una extracción, y ninguna de las dos cosas necesita un agente.
- Trabaja contra un **servidor MCP propio con catálogo cerrado de cuatro herramientas**. Ninguna de las cuatro emite, niega ni cambia estado.
- Cada llamada pasa por **seis ganchos** como middleware: solo-lectura, idempotencia, PII y traza, entre otros. *Un gancho que confía en la skill no es un control* — ese defecto está en E13_hallazgos_del_mcp.md.

Vitalia Salud EPS

Mesa de preautorización · MVP

Ingreso

Consulta anticipada

Bandeja4

Expediente

Panel de operación

Carlos Alberto Ramos Tineo

subsanaciónagente

política v2026_09

Artroscopia de rodilla · PRC-2933 · M23.2 · Trastorno de menisco debido a desgarro o lesión antigua · VIT-ESE · SOL-13f58ae117e3

LO DETERMINISTA · EL MOTOR DECIDE

sin modelo

reproducible

R1

Elegibilidad

activo

Carencia

cumplida

792 días de 60 exigidos

Cobertura

cubierto

elegible, sin carencia pendiente y dentro del tarifario del plan

Copago

S/ 1,660.00

DESGLOSE

regla

deducible pendiente + coaseguro sobre el saldo

tarifa

S/ 9,400.00

coaseguro

S/ 860.00

deducible

S/ 800.00

coaseguro pct

10 %

base coaseguro

S/ 8,600.00

Esta columna no pasó por ningún modelo. La fila de `metrica_costo` del tramo adjudicación vale **US\$ 0.000000**, y esa fila en cero es la prueba —no un hueco en los datos.

LO INTERPRETATIVO · EL MODELO LEE

gpt-4o-mini

propone, no dispone

CAMPO	VALOR	CONF.	CONTRASTE
afiliado_ref	AF-1007777	1.00	catálogo ✓
prestador_id	PRE-0104	1.00	catálogo ✓
dx_cie10	M23.2	1.00	catálogo ✓
procedimiento_codigo	PRC-2933	1.00	catálogo ✓
tipo	programado	1.00	catálogo ✓
documentos	["orden_medica", "informe_medico", "resonancia_magnetica"]	1.00	catálogo ✓

La confianza que declara el modelo **no decide nada**: se guarda para la traza. Lo que decide es la columna «contraste», que es una consulta al catálogo. Un modelo seguro de un código inexistente sigue estando equivocado.

FUNDAMENTO · LAS CLÁUSULAS QUE SOSTIENEN LA DECISIÓN

«genera observación y suspende el plazo de evaluación hasta que se subsane»

protocolos_de_procedimientos_quirurgicos-v2026_09-c02 · Documentos exigibles a toda solicitud programada ·

verificada literal

«toda solicitud de preautorización de un procedimiento programado debe incluir, como mínimo, la orden médica firmada por el médico tratante de la red con su número de colegiatura, el

P4C_EXPEDIENTE_SUBSANACION.PNG · 1440 × 2050 · MITAD SUPERIOR

Vitalia Salud EPS · Anexo K · Álbum de capturas · Parte 1

Jonatan Sánchez · DataPath · 2026-09-06 · pág. 11

La mitad inferior enseña el resultado del agente y lo que se hizo con él:

- **El borrador de tipo observa:** nombra el documento que falta, cita la cláusula que lo exige y da el plazo. Es una petición, no una negativa — y esa diferencia es la que evita que el afiliado empiece de cero.
- **Los controles O1–O6 corrieron igual.** Que la carta sea benigna no la exime: el guardrail de salida no distingue por intención, distingue por control.
- **La traza de la conversación del agente** con su costo y su latencia por tramo, y la bitácora del expediente con la transición a observa y su motivo.

Tres desenlaces, tres expedientes: **autoriza** (P4b), **observa** (P4c) y **negación retenida en hit1** (P4a). Son los tres que el diseño promete, y están los tres a la vista.

«toda solicitud de preautorización de un procedimiento programado debe incluir, como mínimo, la orden médica firmada por el médico tratante de la red con su número de colegiatura, el informe médico que sustenta la indicación, el código del procedimiento propuesto, el diagnóstico codificado según CIE-10, la fecha tentativa y la clínica donde se realizará»

protocolos_de_procedimientos_quirurgicos-v2026_09-c02 · Documentos exigibles a toda solicitud programada ·

verificada literal

GUARDRAIL DE SALIDA · LOS SEIS CONTROLES

CONTROL	QUÉ VERIFICA	RESULTADO
O1 ✓	La cita existe literalmente	las 2 citas coinciden carácter por carácter
O2 ✓	La versión citada estaba vigente	todas las citas son de v2026_09, vigente el 2026-09-05
O3 ✓	Consistencia determinista → prosa	la carta no cita montos y el motor calculó \$/ 1660.00
O4 ✓	Sin negación clínica sin firma	no es una negación por necesidad médica
O5 ✓	Sin PII fuera de destino	destino es el titular: la carta lleva sus datos por diseño
O6 ✓	Esquema y catálogo	1 código(s), las fuentes declaradas y los fundamentos del motor resuelven contra el corpus vigente

Los seis corren siempre y completos, aunque uno ya haya fallado: quien audita tiene que ver todo lo que estaba mal de una sola vez.

BORRADOR DE CARTA

aprobada por el guardrail gpt-4o todavía no es de nadie

Estimado Carlos Alberto Ramos Tineo,

Hemos recibido su solicitud de preautorización para el procedimiento de artroscopia de rodilla con diagnóstico M23.2. Tras revisar la documentación presentada, hemos identificado que falta el informe de terapia física de al menos seis semanas, necesario para completar la evaluación de su solicitud.

Conforme a nuestra política, «toda solicitud de preautorización de un procedimiento programado debe incluir, como mínimo, la orden médica firmada por el médico tratante de la red con su número de colegiatura, el informe médico que sustenta la indicación, el código del procedimiento propuesto, el diagnóstico codificado según CIE-10, la fecha tentativa y la clínica donde se realizará». La ausencia de cualquiera de estos elementos, como es el caso del informe de terapia física, «genera observación y suspende el plazo de evaluación hasta que se subsane».

Este expediente está en agente. La máquina de estados solo admite hit1 → E4: los que están en agente esperan documentos del prestador, no una firma.

P4C_EXPEDIENTE_SUBSANACION.PNG · MITAD INFERIOR

- Lo que mira quien opera la mesa, no quien la construyó: costo por solicitud, hit-rate del caché, p50/p95 por span, distribución del ruteo, actividad del guardrail, feedback y la versión de política vigente.
- El costo se lee de metrica_costo, span a span. Los S/ 0.02 por solicitud son la medición de esta corrida; el S/ 0.86 del Anexo A es el costo costeadado a 7,800 solicitudes/mes con la infraestructura fija de producción. No son la misma cifra y no se mezclan.
 - El panel mide los dos carriles. En una versión anterior medía solo el Carril 1 y el carril que lleva el 41% del volumen no aparecía en la cuenta (E12 §3). El defecto está escrito.
 - La versión de política se muestra siempre, resuelta por el alias politica_actual (ADR-21). La aplicación nunca lee el nombre de la colección: publicar una versión es mover el alias.

Vitalia Salud EPS

Mesa de preautorización · MVP

Ingreso

Consulta anticipada

Bandeja4

Expediente

Panel de operación

política v2026_09
neon ✓ · qdrant ✓ (112 fragmentos)

Panel de operación

Costo por solicitud, caché y latencias. Con las decenas de casos de un MVP un p95 es una cifra frágil —el 95 de veinte casos es el segundo peor—, y se muestra sabiéndolo.

4

SOLICITUDES

S/ 0.02

POR SOLICITUD · MODELOS

40%

ACIERTOS DE CACHE

5/5

CITAS VERIFICADAS

COSTO Y LATENCIA POR TRAMO

TRAMO	LLAM.	US\$	P50 MS	P95 MS
emision	4	0.024002	2108	2652
n1	10	0.001961	2605	3613
extraccion	4	0.000636	1858	1997
adjudicacion	4	0.000000	119	120

adjudicación en US\$ 0.000000 no es un dato que falte: es la decisión, y no cuesta porque no pasa por un modelo.

RUTEO Y CONTROLES

mesa · 2

automática · 1

subsanción · 1

GUARDRAIL

entrada	PERMITIR	1
entrada	BLOQUEAR	1
salida	PERMITIR	24

RETROALIMENTACIÓN

👍 1

👎 0

VERSIONES DE POLÍTICA

VERSIÓN	VIGENTE DESDE	HASTA	FRAGMENTOS	COLECCIÓN
v2026_09 vigente	2026-09-05	—	112	vitalia_politica_v2026_09

La aplicación lee por el alias politica_actual y nunca por el nombre de la colección (ADR-21): publicar una versión nueva es mover el alias, no tocar el código.

P5_PANEL.PNG · 1440 × 900 · VOLCADO COMPLETO EN E11_SERVICIO_Y_MESA.JSON → PANEL

La configuración técnica

Catorce consolas. La aplicación de la Parte 1 afirma cosas —que hay 112 fragmentos de política, que el tramo de adjudicación no pasa por ningún modelo, que las claves no están en el código—. Aquí se abren los proveedores que las ejecutan para que esas afirmaciones se puedan contrastar contra algo que no escribimos nosotros.

Ninguna de las catorce muestra el valor de una clave. Secret Manager enseña nombres; Cloud Run, referencias montadas. Ni la URL del clúster de Qdrant ni la cadena de conexión de Neon aparecen en ninguna imagen. La captura tiene que poder circular con el entregable.

Un límite que se afirma sin poder comprobarlo no vale más que una excusa.

Clúster datalab_aisa_modulo01_jfsh, Qdrant v1.19.0, colección vitalia_politica_v2026_09. Cuatro cosas hay que leer aquí:

- **"points_count": 112** — los 112 fragmentos de E04_ingesta_v2026_09.json, contados por el proveedor y no por nuestro *log*. Once documentos segmentados **por cláusula** (ADR-19), no por número de caracteres.
- **"size": 3072 y "distance": "Cosine"** — text-embedding-3-large. Las colecciones de los laboratorios anteriores tienen 1,536 dimensiones; esa diferencia es la forma más rápida de saber si se está mirando el corpus del MVP o uno viejo.
- **"hnsw_config": m 16, ef_construct 100 y "status": "green"**, con dos segmentos y on_disk_payload activo: el texto_literal del que sale la cita verificada vive en el *payload*, no en un archivo aparte que habría que sincronizar.
- **El bloque Aliases: politica_actual**. La aplicación lee el alias y nunca el nombre de la colección. **Publicar una versión es mover el alias** — y revertir, moverlo de vuelta.

cluster / datalab_aisa_modulo01_jfsh

Upgrade Cluster

Back to Cloud

Welcome

Console

Collections

Tutorial

Datasets

Settings

Get Support

Qdrant v1190

vitalia_politica_v2026_09

PointsInfoOptimizationsMemoryClusterANN RecallSnapshotsVisualizeGraph

Aliases

Create Alias

politica_actual

Collection Info

Actions

```
{
  "status": "green", // Current state of the collection.
  "optimizer_status": "ok", // Current state of the collection
  "indexed_vectors_count": 0 // Approximate number of indexed vectors in the collection.
  "points_count": 112 // Approximate number of points (vectors + payloads) in collect.
  "segments_count": 2 // Number of segments in collection.
  "config": {
    "params": {
      "vectors": {
        "size": 3072 // Size of a vectors used
        "distance": "Cosine" // Type of internal tags, build from payload Distance function _
      }
    }
    "shard_number": 1 // Number of shards the collection has
    "replication_factor": 1 // Number of replicas for each shard
    "write_consistency_factor": 1 // Defines how many replicas should apply the operation for us _
    "on_disk_payload": true // Deprecated: use payload.memory instead.
  }
  "hnsw_config": {
    "m": 16 // Number of edges per node in the index graph.
    "ef_construct": 100 // Number of neighbours to consider during the index building.
    "full_scan_threshold": 10000 // Minimal size threshold (in Kilobytes) below which full-scan _
    "max_indexing_threads": 0 // Number of parallel threads used for background index buildin_
    "on_disk": false // Deprecated: use memory instead.
  }
}
```

- La colección `vitalia_cache_semantico`, abierta en un punto real. Esta captura contesta la pregunta incómoda de todo caché de LLM: **¿qué guarda exactamente, y qué pasa con el respaldo?**
- **La clave es determinista:** `"clave": "v2026_09|todos|salud_mental|carencia"` — versión de política, plan, cobertura e intención. No es un *hash* del texto ni un umbral de similitud. Reformulaciones legítimas de la misma pregunta miden entre 0.598 y 0.787 de coseno, y una pregunta de *otra* cobertura mide 0.780: las bandas se solapan, así que **ningún umbral es seguro por sí solo** (E00_hallazgos_carril0.md §1).
 - **El `payload` lleva citas** junto a la respuesta. *El caché no puede tirar las citas*: si las tirara, el ahorro se pagaría con una afirmación sin respaldo, que es justo el error que el diseño no admite.
 - **`version_id` y `sha256`** del corpus: si se publica `v2026_10`, estas entradas dejan de servir solas, sin tener que acordarse de vaciar nada.
 - Vectors: `Default vector · Length 3072` — el mismo espacio que la colección de política.

Qdrant

cluster / datalab_aisa_modulo01_ffsh

Upgrade Cluster

Back to Cloud

Welcome

Console

Collections

Tutorial

Datasets

Settings

Get Support

vitalia_cache_semantico

PointsInfoOptimizationsMemoryClusterANN RecallSnapshotsVisualizeGraph

Similar to (id)Filter by payload (key:value) or point ID (id:123)

Point 796a2f05-e79a-565a-a616-3e2b7aa0dd95

Payload

```
{  "clave": "v2026_09|todos|salud_mental|carencia"  "consulta": "[Cu\u00e9ntos d\u00edas debo esperar para que me cubran una ...]"  "respuesta": "\"Salud mental | 90 d\u00edas | Integral y Premium\" FU..."  "plan": null  "cobertura": "salud_mental"  "intencion": "carencia"  "citas": [    > 0: {...}  ]  "version_id": "v2026_09"  "ts": "1788651487"  "sha256": "235ac251141f6983160ee4f676f7362815fc6637be2d1c83a5..."}
```

Vectors:Default vectorLength: 3072CopyOpen GraphFind Similar

Point c47178e0-d0e7-5c1f-990a-bb05f959476f

Payload

Vectors:

C02_QDRANT_CACHE_SEMANTICO.PNG · CONSOLA DE QDRANT CLOUD · 2026-09-06 09:18

Vitalia Salud EPS · Anexo K · \u00c1lbum de capturas · Parte 2

Jonatan S\u00e1nchez · DataPath · 2026-09-06 · p\u00e1g. 16

Si sólo se puede enseñar una tabla, es ésta. Cuatro adjudicaciones, y en las cuatro:

- determinista = true y modelo = NULL. El invariante **R1** —lo determinista nunca pasa por un modelo— no es una promesa de la documentación: es una columna.
- carencia_dias_exigidos y carencia_dias_afiliado **guardados**, no recalculados al mostrarlos. Por eso la pantalla puede decir «220 días de 300» meses después y seguir diciendo lo mismo.
- copago_pen **con su** copago_desglose: el importe y de dónde sale, en la misma fila.
- ruta y motivo_ruta: la decisión de escalar queda escrita con su porqué, que es lo que hace revisable el 41% de casos que no se automatizan.

El contraste está en la tabla extraccion, que sí lleva modelo = 'gpt-4o-mini'. Dos tablas, dos naturalezas, y la frontera entre ellas visible en el esquema.

▼ Qdrant Clou... x UI | Qdrant x UI | Qdrant x Neon Cons... x API keys - C x Recibidos - x ChatGPT x traductor - x (2) Faceboo... x Genoma.Wi... x in Feed | Link... x + Pregunta a G

← → ↺ console.neon.tech/app/projects/calm-moon-14929174/branches/br-winter-leaf-ax7i2nwd/tables

Jonatan Fred Free ↕ datapath-labs Admin ↕

Search... CtrlK All OK Ask AI

PROJECT

Connect

Dashboard

Branches

Integrations

Settings

BRANCH

production ↕

Overview

Credentials

Monitoring

Child branches

Postgres database ▼

Tables

production

neondb ▼

Schema

vitalia_mvp ▼

Search... ⌵ ↺ +

adjudicacion

borrador_carta

carta

carta_cita

catalogo_cie10

catalogo_procedimi...

cita

core_afiliado

DATA STRUCTURE

< >

Filters

Sort

Columns

+ Add record

586ms < 1

adj_id text	solicitud_id text	elegible boolean	carencia_ok boolean	carencia_dias_exigidos...	carencia_dias_afiliado...
ADJ-36d0c9c2c2c9	SOL-450ee590fdef	TRUE	FALSE	300	220
ADJ-418c1ed3a97a	SOL-a470a2ee5065	FALSE	TRUE	60	1826
ADJ-b5a1018b12f0	SOL-689ce3eab0e9	TRUE	TRUE	60	427
ADJ-c9b3a0367590	SOL-13f58ae117e3	TRUE	TRUE	60	792

C03_NEON_ADJUDICACION.PNG · CONSOLA DE NEON · PROYECTO DATAPATH-LABS · RAMA PRODUCTION · ESQUEMA VITALIA_MVP

- Una sola fila, y es la que permite responder «¿*contra qué texto se decidió esto?*» sin abrir un correo:
- `version_id` = `v2026_09` y su `sha256`: el corpus entero resumido en un valor. Si alguien reemplaza un PDF, el *hash* deja de cuadrar y la ingesta lo dice.
 - `vigencia_desde` / `vigencia_hasta`: el control O2 del guardrail de salida comprueba contra estas fechas que la cláusula citada estaba vigente el día de la decisión.
 - `aprobado_por` — una persona con nombre, no un proceso. Publicar política es un acto de gobierno, no un despliegue.
 - `coleccion_qdrant` y `fragmentos` = `112`: la fila apunta a la colección de C01 y al número que allí se cuenta. Las dos evidencias se cierran una contra la otra.

PROJECT

Connect

Dashboard

Branches

Integrations

Settings

BRANCH

production

Overview

Credentials

Monitoring

Child branches

Tables

production

neondb

Schema

vitalia_mvp

Search...

catalogo_procedimi...

cita

core_afiliado

core_tarifario

documento

DATA

STRUCTURE

Filters

Sort

Columns

Add record


138ms

version_id	sha256	vigencia_desde	vigencia_hasta	aprobado_por	diff_vs_anterior
v2026_09	65587fd9c64fcfd325a03...	2026-09-05	NULL	curador.politica@vital...	versión base del MV

C04_NEON_POLITICA_VERSION.PNG · CONSOLA DE NEON · ESQUEMA VITALIA_MVP

Es el ADR-10 leído en el dato, y por eso vale más que la pantalla: **el borrador y la carta son dos tablas distintas**. Un texto redactado no es un acto administrativo hasta que alguien lo emite.

- Tres borradores: uno observa y dos niega_administrativa, con `aprobada_guardrail = true` en todos. **Aprobado por el guardrail no es emitido**. Son dos hechos distintos y el esquema los guarda por separado.
- La tabla carta tiene **una sola fila** —la autorización de P4b—. La diferencia entre tres y uno es exactamente lo que el sistema se negó a decidir solo.
- La tabla carta lleva además la restricción que hace de **R3** algo no evitable: `CHECK (tipo <> 'niega_necesidad_medica' OR firma_id IS NOT NULL)`. No es una validación de aplicación que se pueda saltar por otra ruta: la base rechaza la fila.



C05_NEON_BORRADOR_CARTA.PNG · CONSOLA DE NEON · ESQUEMA VITALIA_MVP

Treinta filas, una por tramo ejecutado: extraccion, adjudicacion, emision, n1. Cada una con proveedor, modelo, tokens de entrada y salida, costo, latencia y si hubo acierto de caché. De aquí sale el panel de P5 — **el panel no calcula nada, lee.**

- Las filas de adjudicacion traen proveedor = ninguno, modelo = NULL y 0 tokens. Es la contraparte de C03: R1 mirado desde la contabilidad. **Una fila en cero es la prueba; un tramo ausente sería un hueco en los datos**, y por eso el tramo se escribe igual aunque no cueste nada.
- trace_id y span permiten reconstruir el costo de una solicitud concreta, no sólo el total del mes.
- Los **S/ 0.02** por solicitud del panel salen de sumar estas filas. El **S/ 0.86** del Anexo A es otra cosa: el costo costeado a 7,800 solicitudes/mes con infraestructura fija. **No se mezclan.**

PROJECT

Jonatan Fred · Free

datapath-labs · Admin

Search...

All OK · Ask AI · Upgrade

Connect

Dashboard

Branches

Integrations

Settings

BRANCH

production

Overview

Credentials

Monitoring

Child branches

Postgres database

Tables

SQL Editor

Backup & Restore

Computes

Data API

Roles

Databases

Data masking

Tables

production

neondb

Schema

vitalia_mvp

catalogo_procedimi...

cita

core_afiliado

core_tarifario

documento

evaluacion_guardrail

evaluacion_ragas

evento_estado

extraccion

feedback

firma_medica

metrica_costo

politica_version

solicitud

transicion_valida

turno_agente

DATA

STRUCTURE

Filters

Sort

Columns

+ Add record

137ms

1 - 30 of 30

	metrica_id bigint	solicitud_id text	trace_id text	span text	proveedor text	modelo text	tokens_in integer
☐	185	SOL-689ce3eab0e9	TRC-c9da4c877de4	extraccion	openai	gpt-4o-mini	441
☐	186	SOL-689ce3eab0e9	TRC-c9da4c877de4	adjudicacion	ninguno	NULL	0
☐	187	SOL-689ce3eab0e9	TRC-c9da4c877de4	emision	openai	gpt-4o	1528
☐	188	SOL-13f58ae117e3	TRC-d7263edf279a	extraccion	openai	gpt-4o-mini	444
☐	189	SOL-13f58ae117e3	TRC-d7263edf279a	adjudicacion	ninguno	NULL	0
☐	190	SOL-13f58ae117e3	TRC-d7263edf279a	emision	openai	gpt-4o	1708
☐	191	SOL-450ee590fdef	TRC-f3b17508cd08	extraccion	openai	gpt-4o-mini	420
☐	192	SOL-450ee590fdef	TRC-f3b17508cd08	adjudicacion	ninguno	NULL	0
☐	193	SOL-450ee590fdef	TRC-f3b17508cd08	emision	openai	gpt-4o	1897
☐	194	SOL-a470a2ee5065	TRC-9f06be79e606	extraccion	openai	gpt-4o-mini	489
☐	195	SOL-a470a2ee5065	TRC-9f06be79e606	adjudicacion	ninguno	NULL	0
☐	196	SOL-a470a2ee5065	TRC-9f06be79e606	emision	openai	gpt-4o	1296
☐	197	NULL	NULL	n1	groq	openai/gpt-oss-20b	1318
☐	198	NULL	NULL	n1	groq	openai/gpt-oss-20b	1315
☐	199	NULL	NULL	n1	groq	openai/gpt-oss-20b	1275
☒	200	NULL	NULL	n1	groq	openai/gpt-oss-20b	1441
☐	201	NULL	NULL	n1	qdrant	NULL	0
☐	202	NULL	NULL	n1	groq	openai/gpt-oss-20b	1257
☐	203	NULL	NULL	n1	groq	openai/gpt-oss-20b	1441
☐	204	NULL	NULL	n1	qdrant	NULL	0
☐	205	NULL	NULL	n1	qdrant	NULL	0
☐	206	NULL	NULL	n1	qdrant	NULL	0
☐	207	NULL	NULL	n1	groq	openai/gpt-oss-20b	1315

C06_NEON_METRICA_COSTO.PNG · CONSOLA DE NEON · ESQUEMA VITALIA_MVP

- La captura más densa del álbum.** Servicio vitalia-mesa, revisión vitalia-mesa-00001-srk con el 100% del tráfico, 1 CPU y 2 GiB.
- **Catorce variables de entorno, y las cinco últimas dicen Secreto:** `...:latest` —`DATABASE_URL`, `QDRANT_URL`, `QDRANT_API_KEY`, `OPENAI_API_KEY`, `GROQ_API_KEY`—. El contenedor **no tiene** `variables.sh`: las resuelve Secret Manager en el arranque. Ni la consola muestra los valores, ni la imagen los contiene.
 - Las otras nueve son configuración, no secretos, y se leen enteras: `DB_SCHEMA=vitalia_mvp`, `QDRANT_COLLECTION_ALIAS=politica_actual` —el alias de C01—, `VERSION_POLITICA=2026-09`, `GUARDRAIL_ENGINE=groq`, `GROQ_PROMPT_GUARD_MODEL=meta-llama/llama-prompt-guard-2-86m` y `GROQ_LLAMA_GUARD_MODEL=openai/gpt-oss-safeguard-20b`: las capas 7 y 8 del guardrail, nombradas en la configuración del servicio.
 - **La URL existe pero no es pública.** La organización aplica `constraints/iam.allowedPolicyMemberDomains` y rechaza `allUsers`. Para verlo hay que invocarlo con token o levantar `gcloud run services proxy`. La política efectiva está copiada literal en `E15_despliegue_cloud_run.json`.

Google Cloud

DataPath Labs

Buscar (/) recursos, documentos, productos y más

Buscar

Cloud Run

Descripción general

Servicios

Trabajos

Grupos de trabajadores

Asignaciones de domini...

Detalles del servicio

Prueba

Actualizar

No se realizaron cambios

Volver a implementar

vitalia-mesa

URL: https://vitalia-mesa-465408735025.us-central1.run.app

Región: us-central1

Observabilidad

Historial de revisión

Contenedores

Redes

Seguridad

Escalamiento

Activadores

Fuente

YAML

Revisiones

Administrar el tráfico

Filtro

Filtrar revisiones

Nombre

Tráfico

Implementada ↓

Etiquet

Acciones

vitalia-mesa-00001-srk

100% (a la versión más reciente)

hace 13 horas

+

⋮

Compilación

(no hay información disponible sobre la creación) ⓘ

Fuente

(no hay información disponible sobre la fuente) ⓘ

Comandos y argumentos

(punto de entrada del contenedor)

Límite de CPU

1

Límite de memoria

2GiB

Lanzador de zona de pruebas

Vista previa

Inhabilitada

Variables de entorno (14)

Nombre

Valor

DB_SCHEMA

vitalia_mvp

QDRANT_COLLECTION_NAME

vitalia_politica_v2026_09

QDRANT_COLLECTION_ALIAS

politica_actual

QDRANT_CACHE_COLLECTION

vitalia_cache_semantico

RETRIEVAL_LIMIT

8

VERSION_POLITICA

2026-09

GUARDRAIL_ENGINE

groq

GROQ_PROMPT_GUARD_MODEL

meta-llama/llama-prompt-guard-2-86m

GROQ_LLAMA_GUARD_MODEL

openai/gpt-oss-safeguard-20b

DATABASE_URL

Secreto:vitalia-database-url:latest

QDRANT_URL

Secreto:vitalia-qdrant-url:latest

QDRANT_API_KEY

Secreto:vitalia-qdrant-api-key:latest

OPENAI_API_KEY


Secreto:vitalia-openai-api-key:latest

GROQ_API_KEY

Secreto:vitalia-groq-api-key:latest

C07_CLOUD_RUN_REVISION_Y_VARIABLES.PNG · PROYECTO DATAPATH-LABS-202608

- La pestaña *Observabilidad* del mismo servicio, con las métricas que da la plataforma sin instrumentar nada: recuento de solicitudes, **latencias p50 / p95 / p99**, latencia de extremo a extremo, desglose por etapa —ejecución del usuario, enrutamiento, entrada a la región, arranque— e instancias facturables.
- **Es la capa exterior de la observabilidad, y por sí sola no basta.** Mide la solicitud HTTP; no sabe cuánto costó el tramo de extracción ni si el guardrail cortó. Ese detalle vive en `metrica_costo` (C06) y en el panel de P5. **Las dos capas miden cosas distintas y las dos hacen falta.**
 - **La actividad es de demostración**, no de producción: picos sueltos el 5 y el 6 de septiembre. Decirlo es parte de la evidencia — un gráfico casi vacío presentado como carga sería una afirmación falsa.
 - **Lo que falta está declarado** en §K.6: la instrumentación con LangSmith y la medición de los SLOs J1 (< 2 s), J3 (< 90 s) y J4 (< 5 min) *bajo carga*. Esta pantalla es el punto de partida de esa medición, no su sustituto.



C08_CLOUD_RUN_OBSERVABILIDAD.PNG · ÚLTIMO DÍA · ZONA HORARIA UTC-5

Historial de compilaciones del proyecto. **La del MVP es 1a3e7826**, del 5 de septiembre a las 19:54, **1 min 32 s**, correcta. Las cinco de agosto son de los laboratorios anteriores del curso y están aquí por lo mismo que se enseña la bandeja entera: el entorno es real y tiene historia.

- **La imagen no se construyó en esta máquina.** `gcloud builds submit` sube el contexto, Cloud Build construye y publica en Artifact Registry (`vitalia-mvp/mesa:v1`) y Cloud Run despliega esa imagen. Lo que corre en la nube no depende del Python local ni de que aquí funcione.
- La columna **Estadísticas de seguridad** tiene un *Ver* sólo en la compilación reciente: el análisis de vulnerabilidades del artefacto. No se explotó en esta fase, y se dice.
- Sin *Fuente*, *Ref* ni *Activador*: el despliegue fue **manual y reproducible por comando** (§K.5), no automático desde un repositorio. Automatizarlo es F1 del roadmap, no algo que se pueda dar por hecho.

Estado de la prueba gratuita: quedan S/1,019.23 de crédito y 69 días. Actualiza a una cuenta completa para obtener acceso ilimitado a todas las funciones de Google Cloud. Usa los créditos restantes y paga solo por lo que usas.

Google Cloud

DataPath Labs

cloud build

X

Buscar

Cloud Build / Historial

Cloud Build

Panel

Historial

Repositorios

Activadores

Grupos de trabajadores

Permisos

Historial de compilaciones

Dejar de transmitir compilaciones

En esta página, se muestran tus compilaciones, ordenadas desde la más reciente. Explora los detalles de la compilación para ver los registros, los detalles de ejecución y los artefactos de compilación.

Filtro

Escribir el nombre o valor de la propiedad


	Estado	Compilación	Región	Fuente	Ref	Confirmar	Nombre del activador	Fecha de creación	Duración	Estadísticas de seguridad	
☐	✓	1a3e7826	us-central1	—	—	—	—	5/9/26, 7:54 p.m.	1 min 32 s	Ver	⋮
☐	✓	47c641f5	us-central1	—	—	—	—	19/8/26, 4:34 p.m.	42 s	—	⋮
☐	✓	d73c367d	us-central1	—	—	—	—	19/8/26, 4:24 p.m.	41 s	—	⋮
☐	✓	9679adca	us-central1	—	—	—	—	19/8/26, 4:16 p.m.	38 s	—	⋮
☐	✓	da5057ba	us-central1	—	—	—	—	19/8/26, 4:14 p.m.	34 s	—	⋮
☐	✓	9db06606	us-central1	—	—	—	—	19/8/26, 4:00 p.m.	51 s	—	⋮

C09_CLOUD_BUILD_HISTORIAL.PNG · PROYECTO DATAPATH-LABS-202608

El bucket donde Cloud Build deja el contexto que se le envía en cada `builds submit`. Es la pieza menos vistosa del álbum y aun así merece página propia por dos razones:


- **Cierra la cadena de C09.** Contexto en Storage → construcción en Cloud Build → imagen en Artifact Registry → revisión en Cloud Run. Los cuatro eslabones están retratados y ninguno se afirma de memoria.
- **Es también el sitio donde un despliegue descuidado filtra secretos.** Aquí no: el `.gcloudignore` del proyecto deja fuera `variables.sh`, `.env` y `.gcp/`, de modo que **lo que se sube no contiene ninguna clave**. Que el contenedor las reciba de Secret Manager (C07, C11) sólo sirve si además no viajaron dentro de la imagen.

En el diseño de la fase 1 este bucket es parte del apartado de ingesta y artefactos; aquí aparece con su nombre real, que es lo único que faltaba.



C10_CLOUD_STORAGE_CLOUDBUILD.PNG · PROYECTO DATAPATH-LABS-202608

- vitalia-database-url, vitalia-groq-api-key, vitalia-openai-api-key, vitalia-qdrant-api-key, vitalia-qdrant-url. Replicación automática y encriptación administrada por Google.
- **La consola enseña nombres, no valores**, y esa es exactamente la propiedad que se quería demostrar. Para leer un valor hace falta un permiso distinto del que hace falta para montarlo en un servicio: quien despliega no necesita ver la clave.
 - **QDRANT_URL es un secreto y no una variable de configuración**. No es paranoia de más: la URL del clúster identifica el destino y, junto con la clave, abre el índice entero. Va donde van las claves.
 - **La rotación deja de ser un evento traumático**: se añade una versión al secreto y se redespiega la revisión. No hay que editar código, ni una imagen, ni buscar en cuántos sitios estaba copiada.
 - En el repositorio del proyecto, variables.sh, .env y .gcp/ están en .gitignore desde el primer día. Secret Manager es la otra mitad de la misma regla.



C11_SECRET_MANAGER_SECRETOS.PNG · PROYECTO DATAPATH-LABS-202608

Model Armor no fue una idea de última hora: está en el ADR-08 de la fase 1 y en los diagramas D-06, D-11 y D-12, escrito meses antes de que existiera este recurso. Esta captura es la confirmación empírica de una decisión ya tomada.

- **Recurso:** projects/datapath-labs-202608/locations/us-central1/templates/vitalia-preauth, creado el 6 de septiembre de 2026 a las 8:37.
- **Residencia de los datos: Aplicada** — el contenido inspeccionado no sale de la región, lo que en un caso de salud no es un detalle de configuración sino una condición.
- **El servicio es regional**, y eso cuesta una tarde si no se sabe: gcloud model-armor ... pega al endpoint global y devuelve PERMISSION_DENIED aun siendo *owner* con la API habilitada. Hay que usar modelarmor.us-central1.rep.googleapis.com, y el error no lo dice.
- **En la consola se llega por Seguridad → Model Armor**, dentro de Security Command Center — no es un producto de la sección de IA, y por eso cuesta encontrarlo.

Estado de la prueba gratuita: quedan S/1,019.23 de crédito y 69 días. Actualiza a una cuenta completa para obtener acceso ilimitado a todas las funciones de Google Cloud. Usa los créditos restantes y paga so

Google Cloud

DataPath Labs

model armor

X

Buscar

Seguridad / Model Armor / Plantilla: vitalia-preauth

Seguridad

Security Command Center

Descripción general

Búsqueda de gráficos

Problemas

Resultados

Recursos

Cumplimiento

Administración de la ...

Reglas

Fuentes

Configuración

Detecciones y controles

Google SecOps

Fraud Defense

Model Armor

Web Security Scanner

Cyber Insurance Hub

Autorización Binaria

Notificaciones de aviso

Marketplace

Notas de versión

←

Detalles de la plantilla

Editar

Borrar

Referencia de la API

Nombre del recurso

projects/datapath-labs-202608/locations/us-central1/templates/vitalia-preauth

Ubicación

us-central1

Residencia de los datos

Aplicada

Etiquetas

Ninguno

Versión

Fecha de creación

6 sept 2026, 8:37:38 a.m.

Fecha de actualización

6 sept 2026, 8:37:38 a.m.

Detecciones

Detección de URLs maliciosas

Habilitada

Detección de inyección de instrucciones y jailbreak

Habilitada

Nivel de confianza

Bajo y superior

Protección de datos sensibles

Habilitada

Tipo de detección

Básica

IA responsable

El nivel de confianza representa la probabilidad de que los resultados coincidan con un tipo de filtro de contenido. Para una aplicación más estricta, establece el nivel de confianza en "Bajo y superior" para detectar la mayoría del contenido que se incluye en un tipo de filtro.

Filtro de contenido

Nivel de confianza

Incitación al odio o a la violencia

Medio y superior

Peligroso

Medio y superior

Sexualmente explícito

Medio y superior

Hostigamiento

Medio y superior

C12_MODEL_ARMOR_PLANTILLA.PNG · PLANTILLA VITALIA-PREAUTH

Vitalia Salud EPS · Anexo K · Álbum de capturas · Parte 2

Jonatan Sánchez · DataPath · 2026-09-06 · pág. 26

La configuración exacta contra la que se midió E16_model_armor_vs_capas_propias.json: URLs maliciosas **habilitada**; inyección de instrucciones y jailbreak **habilitada**, **Bajo y superior**; protección de datos sensibles **habilitada**, **básica**; y los cuatro filtros de IA responsable —odio, peligroso, sexualmente explícito, hostigamiento— en **Medio y superior**.

- **Se activó y se midió, no se declaró.** Mismos 20 casos del red team, tres motores: capas propias **16/16**, Model Armor solo **11/16**, mixto **16/16**. Cero falsos positivos en los tres.
- **Las once que atrapa salen todas de pi_and_jailbreak.** rai, malicious_uris y sdp no marcaron ni un caso. Los cinco que deja pasar —R04, R05, R13, R14, R15— dependen del modismo en español o de las reglas de Vitalia: **ningún proveedor gestionado sabe que aquí no se niega sin firma**.
- Por eso el motor recomendado es mixto: **suma, no sustituye**. Es exactamente lo que el ADR-08 decidió antes de tener el número.
- **Al pie, Configuración de registros: Inhabilitado.** Sin log_sanitize_operations no hay rastro en Cloud Logging de cada inspección, así que la evidencia de las llamadas es la corrida de E16, no un panel del proveedor. **Se dice en vez de dejar que se suponga**.

Estado de la prueba gratuita: quedan \$/1,019.23 de crédito y 69 días. Actualiza a una cuenta completa para obtener acceso ilimitado a todas las funciones de Google Cloud. Usa los créditos restantes y paga solo por lo que usas.

Google Cloud

DataPath Labs

model armor

Buscar

Seguridad / Model Armor / Plantilla: vitalia-preauth

Seguridad

Security Command Center

Descripción general

Búsqueda de gráficos

Problemas

Resultados

Recursos

Cumplimiento

Administración de la ...

Reglas

Fuentes

Configuración

Detecciones y controles

Google SecOps

Fraud Defense

Model Armor

Web Security Scanner

Cyber Insurance Hub

Autorización Binaria

Notificaciones de aviso

Mediatalegra

←

Detalles de la plantilla

Editar

Borrar

Referencia de la API

Fecha de creación

6 sept 2026, 8:37:38 a.m.

Fecha de actualización

6 sept 2026, 8:37:38 a.m.

Detecciones

Detección de URLs maliciosas	Habilitada
Detección de inyección de instrucciones y jailbreak	Habilitada
Nivel de confianza	Bajo y superior
Protección de datos sensibles	Habilitada
Tipo de detección	Básica

IA responsable

El nivel de confianza representa la probabilidad de que los resultados coincidan con un tipo de filtro de contenido. Para una aplicación más estricta, establece el nivel de confianza en "Bajo y superior" para detectar la mayoría del contenido que se incluye en un tipo de filtro.

Filtro de contenido	Nivel de confianza
Incitación al odio o a la violencia	Medio y superior
Peligroso	Medio y superior
Sexualmente explícito	Medio y superior
Hostigamiento	Medio y superior

Configuración de registros

Operaciones actuales registradas para esta plantilla de Model Armor


Operaciones de plantilla	Inhabilitado
Instrucciones y respuestas	Inhabilitado

C13_MODEL_ARMOR_DETECCIONES.PNG · PLANTILLA VITALIA-PREAUTH · DETECCIONES Y CONFIGURACIÓN DE REGISTROS

Vitalia Salud EPS · Anexo K · Álbum de capturas · Parte 2 Jonatan Sánchez · DataPath · 2026-09-06 · pág. 27

El consumo del mes en Groq: **US\$ 0.06 de gasto total**, con openai/gpt-oss-safeguard-20b —la capa 8 del guardrail— como principal contribuyente y la actividad concentrada el 5 y el 6 de septiembre, que son los días en que se construyó y se midió el MVP.

- **Cierra el círculo de C06.** La contabilidad interna dice S/ 0.02 por solicitud; el proveedor dice seis centavos de dólar en el mes. Las dos cifras se sostienen porque miden el mismo tráfico desde los dos lados, y ninguna de las dos es el S/ 0.86 costado a volumen de producción.
- **Groq está donde está por latencia, no por precio.** El router elige gpt-oss-20b para el Carril 0 porque **J1 exige p95 < 2 s**: manda la latencia, no la capacidad. Que además salga barato es una consecuencia, no el criterio.
- El guardrail cortocircuita en la primera capa que bloquea (veto **V3**): **no se paga Groq si una regex ya decidió**. Esta factura es el efecto de esa decisión, medido.



C14_GROQ_CONSUMO.PNG · CONSOLA DE GROQ · USAGE · SEPTIEMBRE 2026 · DATOS EN UTC

LO QUE ESTAS VEINTIUNA CAPTURAS SOSTIENEN

- **R1** · lo determinista nunca pasa por un modelo — C03 (determinista = true, modelo = NULL) y C06 (tramo de adjudicación con proveedor ninguno y 0 tokens), con su lectura en pantalla en P4a.
- **R2** · ninguna afirmación sobre política sin cita textual — P2 y P4a abajo, respaldadas por C01 (112 fragmentos, texto_literal en el *payload*) y C04 (versión sellada con sha256 y vigencia).
- **R3** · ninguna negación por necesidad médica sin firma — C05, y la restricción CHECK que la hace inevitable.
- **ADR-10** · el sistema nunca niega solo — P4a en hit1 y C05: tres borradores aprobados, una sola carta emitida.
- **ADR-21** · acceso por alias — el bloque *Alias*es de C01 y la variable QDRANT_COLLECTION_ALIAS de C07.
- **ADR-08** · guardrail propio y Model Armor — C12 y C13, con el número que lo justifica.
- **Las claves nunca están en el código** — C11 (nombres), C07 (referencias montadas) y C10 (lo que se sube a construir no las lleva).

LO QUE ESTAS CAPTURAS NO DEMUESTRAN, DICHO ANTES DE QUE NADIE LO BUSQUE

- **El volumen es de demostración.** C08 enseña picos sueltos, no 7,800 solicitudes/mes. Los SLOs J1, J3 y J4 *bajo carga* siguen sin medirse.
- **Model Armor no registra sus operaciones** (C13, al pie): la evidencia de las llamadas es la corrida de E16, no un panel del proveedor. Y sigue sin pasarse por él la **salida** del modelo.
- **La URL de Cloud Run no es pública** (C07): cerrada por constraints/iam.allowedPolicyMemberDomains a nivel de organización. Se ve con token o por proxy, y la política efectiva está copiada literal en E15.
- **No hay integración con el core**, ni firma digital real, ni Identity Platform. Está en §K.6 con nombre y apellido, y en el roadmap de la fase 1 con fecha.
- **Faltan S05** (denso vs. híbrido con recall@k), **S06** (RAGAS), **S10** (LangSmith) y **S03** (kind + Helm + Ollama como N3).

El MVP no demuestra que el sistema sea capaz de decidir. Demuestra lo contrario, que es lo que este diseño vino a sostener: en P4a hay una carta de negación **escrita, controlada y sin emitir**, esperando a una persona. El expediente está en hit1 y la máquina de estados no tiene ninguna transición que lo saque de ahí sin que alguien firme.

Eso es el ADR-10, y no depende de que nadie se acuerde de aplicarlo.