


GOBIERNO DE LA SOLUCION - GUARDRAILS, CONTROL HUMANO Y LLMOps

1 · GUARDRAIL DE ENTRADA ocho capas en orden barato -> caro · la primera que bloquea corta la cadena · politica FAIL-CLOSE



CAPA 6

URL y phishing

60+ TLDs, 20+ acortadores

\_listas\_

CAPA 7

Prompt Guard 2

MALICIOUS / BENIGN

\_modelo 86M\_

CAPA 8


Llama Guard 4

safe / unsafe · S1-S13


\_modelo 12B\_

DECISIONES: **PERMITIR** · **TRANSFORMAR** (enmascarar el dato sensible) · **CONFIRMAR** (pide confirmacion al usuario) · **BLOQUEAR** | Registro: capa = pii · categoria = dni · decision = mask · confianza = alta (nunca se registra el valor completo)


2 · CONTROL HUMANO EN EL CIRCUITO (HITL)



3 · TRAZABILIDAD Y VERSIONADO DE LA POLITICA (falla F4)



4 · CICLO DE VIDA LLMOps cada transicion tiene una compuerta automatica



PRODUCCION

Cloud Run + API Gateway SLO p95 &lt; 2 s

MONITOREO

trazas, costo por span, deriva y feedback

COMPUERTAS: evaluacion no supera el golden set -&gt; no pasa a staging | reversiones al apelar suben -&gt; el canary retrocede automaticamente | cambia la politica -&gt; se reindexa, se evalua y recien se publica

5 · EL TRIO DE METRICAS QUE SIEMPRE SE REPORTA JUNTO



AUTOR: Jonatan Sanchez - DataPath | AI Solutions Architect

LEYENDA / NOTAS

- Guardrails y seguridad
- Control humano obligatorio
- Trazabilidad y versionado
- Ciclo de vida y operacion

Un porcentaje de automatizacion que sube mientras suben las reversiones no es una mejora: es el anti-patron PXDX. Por eso el trio va en el tablero del supervisor y en el comite, no en un anexo.

|          |                                                    |  |  |
|----------|----------------------------------------------------|--|--|
| PROYECTO | Mesa de preautorizacion medica - Vitalia Salud EPS |  |  |
| DIAGRAMA | Gobierno: guardrails, HITL y LLMOps                |  |  |
| NIVEL    | Logico - control y operacion                       |  |  |

CODIGO  
D-08

VERSION  
1.3

FECHA  
2026-09-05