

ESTRUCTURA DE COSTOS DE LA PLATAFORMA Y EFECTO EN EL RETORNO

S/ 6,700 / mes

run cloud total
produccion + no productivos + soporte

S/ 0.86

por solicitud
preautorizada

75%

de la factura es fijo:
no depende del volumen


3.8%

de la factura son
tokens de LLM


8%

del costo unitario del
proceso TO-BE


A · COMPOSICION DE LA FACTURA MENSUAL DE PRODUCCION USD 1,406 / mes



B · FIJO CONTRA VARIABLE por que la factura casi no crece con el volumen



C · COSTO UNITARIO SEGUN VOLUMEN S/ por solicitud, run cloud completo



D · RECONCILIACION CON EL PRESUPUESTO Y EFECTO EN EL RETORNO


Linea del caso de negocio (05 §3)	Presupuestado	Bottom-up	Diferencia
Inferencia (extraccion E1 + RAG)	3,000	643	-2,357
Infraestructura cloud	4,500	5,201	+701
Observabilidad, tracing y guardrails	1,200	856	-344
TOTAL CLOUD · S/ por mes	8,700	6,700	-2,000

EFECTO EN EL RETORNO valor capturable sin cambios: S/ 96,600 / mes

PAYBACK 8.6 meses era 8.8	VAN @ 12% · 3 años S/ 1.17 M era S/ 1.13 M	TIR 88% era 85%
---------------------------------	--	-----------------------

La diferencia NO se descuenta. El costo de run comprometido sigue siendo S/ 21,700 / mes y los S/ 2,000 quedan como contingencia hasta que tres meses de facturacion etiquetada lo confirmen. Lo que si corrige el costeo es el reparto: se presupuesto 3.4x de mas en inferencia y de menos en conectividad - VPN, PSC, NAT e instancias minimas suman S/ 1,480 / mes, mas del doble que toda la inferencia junta.

E · SENSIBILIDAD que mueve la factura y que decision se toma



El unico escenario que rompe el presupuesto es una decision comercial de Google, no una necesidad tecnica de este volumen. Cloud Armor Standard cubre WAF, reglas y limitacion de tasa para las 7,800 solicitudes al mes de Vitalia; Enterprise solo se justifica si aparece exposicion real a denegacion de servicio. Todo lo demas cabe dentro de los S/ 8,700 ya presupuestados.

AUTOR: Jonatan Sanchez - DataPath | AI Solutions Architect

LEYENDA / NOTAS

- Costo fijo: disponibilidad, enlaces privados, instancias minimas
- Costo variable: escala con el volumen de solicitudes
- Escenario que baja la factura o mejora el retorno
- Escenario que rompe el presupuesto

Precio de lista publico, region us-central1, tarifas consultadas el 2026-09-05. Tipo de cambio declarado: S/ 3.75 por USD. Model Armor, Vertex AI Ranking e Identity Platform van estimados: falta confirmarlos en el calculador de Google Cloud. Detalle servicio por servicio, drivers y controles FinOps en 05a_costeo_cloud.md.

PROYECTO

Mesa de preautorizacion medica - Vitalia Salud EPS

DIAGRAMA

Costeo cloud y economia unitaria

NIVEL

Economico - costo de run y ROI

CODIGO
D-12

VERSION
1.3

FECHA
2026-09-05