


SECUENCIA END-TO-END - DEL PORTAL A LA CARTA SELLADA, CON PRESUPUESTO DE LATENCIA

OBJETIVO DE SERVICIO J4 extremo a extremo p95 < 5 min J3 adjudicacion p95 < 90 s J1 consulta anticipada N1 p95 < 2 s J5 emision p95 < 10 s al 99.9%
El reloj de negocio es otro y mas largo: TAT p95 <= 2.5 dias habiles en programados y <= 24 h en urgentes. La diferencia entre ambos relojes es, exactamente, el tiempo de espera humana que este diseno viene a eliminar.



PRESUPUESTO DE LATENCIA p95 · el timeout de cada tramo se fija aqui, no en el codigo de cada servicio

objetivo del tramo	humano	< 0.3 s	< 0.2 s	8 s	12 s	13 s	6 s	30 s	2 s	< 0.1 s	5 s
J3 = 90 s p95	guardrail 8 s	extraccion 25 s			determinista 6 s	interpretativo 30 s			emision 5 s	holgura 16 s	
El presupuesto no se reparte a partes iguales: el tramo interpretativo se lleva un tercio porque es el unico donde el modelo genera prosa que despues hay que verificar. Si un tramo agota su timeout no se reintenta indefinidamente: se baja de nivel de automatizacion (N0-N5 en 07 seccion 4.2) y el caso cae al carril manual, que nunca desaparece. El agente de subsanacion vive fuera de este reloj: su ciclo es de dias porque espera al prestador.											

AUTOR: Jonatan Sanchez - DataPath | AI Solutions Architect

LEYENDA / NOTAS

- Orquestacion y control del flujo
- Frontera y guardrails (entrada y salida)
- Modelos, indice vectorial y rerank
- Sistemas de registro y emision

- Intervencion humana obligatoria
- Canal del prestador

El camino dibujado es el del carril automatico. Toda derivacion sale en T10 y termina en el mismo lugar: la mesa.
Ningun tramo puede autorizar una negacion por necesidad medica; esa transicion solo existe pasando por la fila HUMANO.
SLOs por jornada, degradacion N0-N5 y plan de carga P1-P7 en 07_operacion_y_produccion.md.

PROYECTO	Mesa de preautorizacion medica - Vitalia Salud EPS	
DIAGRAMA	Secuencia end-to-end y latencia por tramo	
NIVEL	Logico - comportamiento y SLO	

CODIGO
D-14

VERSION
1.3

FECHA
2026-09-05